

Fundamentos de Estadística I

Daniel Soto Villada

21 de agosto de 2026

Índice general

1. Clase 1	3
1.1. Introducción a la Estadística	3
1.1.1. Conceptos Fundamentales	3
1.1.2. Tipos de Datos y Niveles de Medición	4
1.1.3. Recopilación de Datos y Muestreo	4
1.1.4. Significancia Estadística vs. Práctica	5
2. Clase 2	6
2.1. Descripción de Datos y Análisis de Muestras	6
2.1.1. Técnicas de la Estadística Descriptiva	6
2.1.2. Inferencia a partir de Muestras	6
2.2. Contraste de Hipótesis	7
2.2.1. Concepto y Metodología	7
2.2.2. Complemento: Tipos de Error en el Contraste	7
2.3. Medida de Relaciones	7
2.3.1. Complemento: Coeficiente de Correlación Lineal	8
2.4. Establecimiento de Predicciones	8
2.5. El Método Estadístico	8
2.5.1. El Método Científico	8
2.5.2. Estadística y Método Científico	9
2.5.3. Etapas del Método Estadístico	9
2.6. Método Científico frente a Método Estadístico	10
3. Clase 3	12
3.1. Estructura y Fuentes de los Datos	12
3.1.1. Datos	12
3.1.2. Fuentes de Datos	12
3.1.3. Variable	13
3.1.4. Elementos	13
3.2. Datos de Sección Transversal y de Series de Tiempo	13
3.2.1. Datos de Sección Transversal	13
3.2.2. Datos de Series de Tiempo	13
3.3. Errores en la Adquisición de Datos	13
3.3.1. Tipos de Errores	13
3.3.2. Verificación de Consistencia	14

3.4.	Razones Prácticas para Utilizar una Muestra	14
3.5.	Pensamiento Crítico ante la Estadística	14
3.5.1.	Usos Inadecuados de la Estadística	14
3.5.2.	Gráficas y su Uso Inadecuado	14
3.5.3.	Resultados Reportados	15
3.5.4.	Otros Aspectos a Considerar	15
3.6.	Recolección de Datos Muestrales	15
3.6.1.	Fundamentos de la Recolección de Datos	15
3.6.2.	Estudios Retrospectivos y Prospectivos	16
3.7.	Estructura de un Conjunto de Datos	16
3.8.	Pensamiento Estadístico	16
3.8.1.	Concepto Clave	16
3.8.2.	Contexto y Fuente de los Datos	17
3.8.3.	Método de Muestreo	17
3.8.4.	Conclusiones e Implicaciones Prácticas	17
3.8.5.	Significancia Estadística y Significancia Práctica	17
3.8.6.	Definición de Pensamiento Estadístico	18
3.9.	Tipos de Datos	18
3.9.1.	Parámetro y Estadístico	18
3.9.2.	Datos Cuantitativos	18
3.9.3.	Datos Cualitativos	19
3.9.4.	Niveles de Medición	19
4.	Clase 4	21
4.1.	Pensamiento Crítico y Comunicación Estadística	21
4.1.1.	Distorsiones en las Gráficas	21
4.1.2.	Resultados Autoinformados	21
4.1.3.	Lista de Verificación para Interpretar Resultados	22
4.2.	Muestreo Probabilístico y Diseños Multietápico	22
4.2.1.	Muestreo Probabilístico	22
4.2.2.	Muestreo Multietápico	22
4.3.	Organización de Datos Multidimensionales	23
4.3.1.	Matriz de Datos	23
4.3.2.	Tablas de Contingencia	23
4.3.3.	Relaciones entre Varias Variables	23
5.	Clase 5	24
5.1.	Descripción, exploración y comparación de datos	24
5.1.1.	Introducción y características de los datos	24
5.1.2.	Distribuciones de frecuencias	24
5.1.3.	Procedimiento de construcción para datos cuantitativos	25
5.1.4.	Implementación tecnológica	27
5.1.5.	Histogramas y Distribución Normal	28
5.1.6.	Otras técnicas visuales y gráficas	28
5.1.7.	Formas de las curvas de frecuencias	29
5.1.8.	Diagramas de dispersión y gráficas de puntos	30

Capítulo 1

Clase 1

1.1. Introducción a la Estadística

La estadística es la ciencia que se encarga de planear estudios y experimentos, obtener datos, organizarlos, resumirlos, presentarlos, analizarlos e interpretarlos para obtener conclusiones basadas en ellos. El pensamiento estadístico exige evaluar el contexto, la fuente y el método de muestreo antes de realizar cualquier cálculo, priorizando el sentido común sobre la aplicación irreflexiva de fórmulas.

1.1.1. Conceptos Fundamentales

Para estructurar cualquier análisis, es necesario distinguir entre la población de estudio y la muestra extraída de ella.

Cuadro 1.1:

Concepto	Definición
Población	Conjunto completo de todos los elementos sobre los que se desea investigar.
Muestra	Subconjunto de miembros seleccionados de una población.
Censo	Conjunto de datos de todos los miembros de la población.
Parámetro	Medición numérica que describe una característica de la población.
Dato estadístico	Medición numérica que describe una característica de la muestra.

La notación matemática estándar diferencia las mediciones poblacionales de las muestrales:

Parámetros poblacionales: μ, σ, σ^2, p

Estadísticos muestrales: $\bar{x}, s, s^2, \hat{p}$

1.1.2. Tipos de Datos y Niveles de Medición

El tipo de dato determina qué procedimientos estadísticos son apropiados. Realizar cálculos con datos inapropiados (como promediar códigos postales o números de camisetas) carece de sentido matemático.

Cuadro 1.2:

Nivel	Características y Ejemplo
Nominal	Solo categorías o etiquetas. No se pueden ordenar ni calcular. (Ej. Colores, géneros).
Ordinal	Se pueden ordenar, pero las diferencias entre valores carecen de significado. (Ej. Calificaciones A, B, C).
De intervalo	Orden y diferencias significativas, pero sin un punto de partida cero natural. (Ej. Temperatura en °C).
De razón	Orden, diferencias significativas y un cero natural absoluto. Las razones tienen sentido. (Ej. Distancias, pesos).

1.1.3. Recopilación de Datos y Muestreo

Si los datos muestrales no se recopilan de manera apropiada, pueden ser tan inútiles que ningún tratamiento estadístico pueda salvarlos. Las muestras de respuesta voluntaria (autoseleccionadas) suelen estar sesgadas y no son representativas.

Cuadro 1.3:

Método	Descripción
Aleatorio simple	Cada muestra posible del mismo tamaño n tiene la misma probabilidad de ser elegida.
Sistemático	Se selecciona un punto de inicio y luego cada k -ésimo elemento de la población.
Estratificado	Se subdivide la población en estratos con características comunes y se extrae una muestra de cada uno.

Continued on next page

Cuadro 1.3: (Continued)

Método	Descripción
Conglomerados	Se divide el área en secciones, se eligen algunas al azar y se toman todos los miembros de esas secciones.
Conveniencia	Se utilizan datos que son muy fáciles de obtener (alto riesgo de sesgo).

1.1.4. Significancia Estadística vs. Práctica

Al sacar conclusiones, se debe determinar si los resultados tienen significancia estadística y significancia práctica.

- **Significancia estadística:** Se logra cuando un resultado es muy improbable que ocurra por casualidad. El criterio común es que la probabilidad de ocurrencia por azar sea del 5 % o menos:

$$P(\text{evento por casualidad}) \leq 0,05$$

- **Significancia práctica:** Ocurre cuando el tratamiento o hallazgo tiene una diferencia lo suficientemente grande como para justificar su uso o ser útil en la realidad, independientemente de los cálculos matemáticos.

Capítulo 2

Clase 2

2.1. Descripción de Datos y Análisis de Muestras

2.1.1. Técnicas de la Estadística Descriptiva

Los estudios estadísticos, para poseer una cierta fiabilidad, deben basarse en la recogida de muchos datos: cuantos más, mejor. La Estadística dispone de técnicas específicas para cada etapa del tratamiento de la información:

Cuadro 2.1:

Etapas	Descripción
Recogida de datos	Obtener datos lo más representativos posible de la población.
Resumen en tablas	Organizar los datos en tablas ordenadas de frecuencias.
Representación gráfica	Representar gráficamente las tablas obtenidas.
Medidas representativas	Efectuar medidas centrales, de dispersión, asimetría, aplastamiento y correlaciones.

Al estudio de estos aspectos se le denomina Estadística Descriptiva. La mayoría de los trabajos de nivel introductorio se limitan a estos aspectos.

2.1.2. Inferencia a partir de Muestras

Una vez seleccionada la muestra mediante los procedimientos estudiados en la Clase 1, sus resultados pueden utilizarse para estimar parámetros o contrastar afirmaciones acerca de la población. Este proceso de generalización constituye la Estadística Inferencial y exige cuantificar la incertidumbre asociada a las conclusiones.

2.2. Contraste de Hipótesis

En la actualidad, el contraste de hipótesis es la parte de la Estadística más usada en todo tipo de investigaciones. Ningún trabajo de nivel universitario o profesional se admite sin estar basado en un Diseño de Experimentos y en el uso de las técnicas de Contraste de Hipótesis.

2.2.1. Concepto y Metodología

Consiste en plantear una hipótesis (llamada nula) frente a otra alternativa, recoger datos representativos y comprobar si estos son consistentes con las hipótesis o no. Requiere de una metodología rigurosa.

Preguntas típicas que se resuelven mediante contraste de hipótesis:

- ¿Ha mejorado el rendimiento de los estudiantes con el nuevo modelo de estudios?
- ¿Es el nuevo medicamento mejor que el anterior?
- ¿La duración de una bombilla es superior a mil horas?

Casi ningún producto entra en el mercado sin estudios estadísticos que apoyen la hipótesis con que se promocionan. Las técnicas usadas forman un cuerpo de teoría muy amplio llamado Estadística Inferencial y Diseño de Experimentos.

2.2.2. Complemento: Tipos de Error en el Contraste

Al realizar un contraste de hipótesis, existe la posibilidad de cometer dos tipos de error:

Cuadro 2.2:

	H_0 verdadera	H_0 falsa
Rechazar H_0	Error tipo I (probabilidad α)	Decisión correcta
No rechazar H_0	Decisión correcta	Error tipo II (probabilidad β)

2.3. Medida de Relaciones

En la Sociedad y la Naturaleza se pueden descubrir relaciones y paralelismos que, en algunos casos, permiten representar mediante una fórmula una relación entre dos o más variables. Se llama Correlación al estudio de estas relaciones.

Ejemplos:

- En la Sociedad: ¿El nivel de estudios está correlacionado con los ingresos?

- En la Naturaleza: ¿Las lluvias están correlacionadas con las cosechas?

Aunque el caso más frecuente es el de la comparación de dos variables, cada día se emprenden más estudios en los que algunas variables se relacionan con varias otras, llamadas explicativas.

Estos paralelismos no se deben confundir con relaciones causa-efecto, que tienen tratamientos más profundos. La correlación no implica causalidad.

2.3.1. Complemento: Coeficiente de Correlación Lineal

La fuerza de la asociación lineal entre dos variables se mide mediante el coeficiente de correlación lineal r , el cual satisface:

$$-1 \leq r \leq 1$$

Un valor de r cercano a $+1$ indica una correlación lineal positiva fuerte; un valor cercano a -1 indica una correlación lineal negativa fuerte; un valor cercano a 0 indica ausencia de correlación lineal.

2.4. Establecimiento de Predicciones

Los datos recogidos en un estudio pueden presentar tendencias o ciclos que quizás permitan predecir qué va a ocurrir fuera del rango de datos obtenido. Se distinguen dos tipos de predicción:

- **Extrapolación:** predecir qué va a ocurrir en el futuro, fuera del rango observado.
- **Interpolación:** predecir valores intermedios dentro del rango observado.

Esta técnica también puede servir para completar datos perdidos o erróneos. En el establecimiento de las predicciones es fundamental conocer los márgenes de error. Las técnicas consiguientes están recogidas en la Teoría de la Regresión.

2.5. El Método Estadístico

El método estadístico es el procedimiento mediante el cual se sistematiza y organiza el proceso de aprendizaje iterativo para convertir los datos en información y esta en conocimiento:

$$\text{Datos} \xrightarrow{\text{Estadística Descriptiva}} \text{Información} \xrightarrow{\text{Inferencia Estadística}} \text{Conocimiento}$$

2.5.1. El Método Científico

El método científico es un método o procedimiento que ha caracterizado a la ciencia natural desde el siglo XVII, que consiste en la observación sistemática, medición, experimentación, la formulación, análisis y modificación de las hipótesis. Sus etapas son:

1. Planteamiento del problema.
2. Revisión de la literatura.
3. Formulación de hipótesis.
4. Observación y experimentación.
5. Elaboración de conclusiones.

2.5.2. Estadística y Método Científico

El método científico está compuesto por los siguientes pasos:

1. Formular una teoría (problema).
2. Recoger datos para probar la teoría.
3. Analizar los datos.
4. Interpretar los resultados y tomar una decisión.

La ciencia está, por lo tanto, todo el tiempo revisando sus teorías. La Estadística no es un conjunto de técnicas aisladas unas de otras, sino que, en conjunto con el método científico, entrega un procedimiento analítico para tomar decisiones.

2.5.3. Etapas del Método Estadístico

Para tener éxito en una investigación estadística se deben seguir las siguientes etapas:

Cuadro 2.3:

Etapas	Descripción
Formulación del problema	Especificación del problema y definición de los objetivos. Crear conceptos precisos, formular preguntas claras, imponer límites teniendo en cuenta dinero y tiempo disponible.
Diseño del experimento	Obtener un máximo de información con un mínimo de error, dinero y tiempo. Determinar el tamaño de la muestra. Saber si la investigación es controlada u observacional.
Colección de datos	Muestreo: método usado para la recolección de datos.

Continued on next page

Cuadro 2.3: (Continued)

Etapas	Descripción
Presentación y análisis	Ordenar datos en forma legible y condensada (diagramas, gráficas). Calcular medidas descriptivas básicas.
Inferencia y decisiones	Formular y obtener conclusiones o establecer generalizaciones acerca de la población.

En resumen, se necesita:

1. Definición del problema de estudio y objetivos del mismo.
2. Selección de la información necesaria para realizar el estudio.
3. Recogida de la información (depende del presupuesto y la calidad exigida).
4. Ordenación y clasificación de la información en tablas y gráficos.
5. Resumen de los datos mediante medidas de posición, dispersión, asimetría y concentración.
6. Análisis estadístico formal obteniendo hipótesis y contrastándolas.
7. Interpretación de resultados y extracción de conclusiones.
8. Extrapolación y predicción.

2.6. Método Científico frente a Método Estadístico

Cuadro 2.4:

Método Científico	Método Estadístico
Conjunto sistemático de procesos en los que se basa la ciencia para explicar cualquier fenómeno y las leyes que lo administran.	Adaptación del método científico a un área del conocimiento, aportando la planificación de la investigación.
Conjunto de procedimientos e instrumentos de la investigación científica que construye el camino reflexivo, sistemático, controlado y crítico para la adquisición del conocimiento.	Proceso de obtención, representación, simplificación, análisis, interpretación y proyección de las características de un estudio para una mejor comprensión de la realidad y una optimización en la toma de decisiones.

Continued on next page

Cuadro 2.4: (Continued)

Método Científico	Método Estadístico
Sigue las interrogantes: observación, preguntas, hipótesis, experimentación, conclusiones, documentación y nuevos descubrimientos.	Herramienta poderosa de precisión científica en la medida en que se combine con los métodos cualitativos y se emplee de acuerdo a las necesidades y al sano criterio.
Consiste en la observación sistemática, medición y experimentación, y la formulación, análisis y modificación de la hipótesis.	Proporciona las técnicas necesarias para recolectar y analizar la información requerida. Se distingue una fase de planificación y otra de ejecución.
Ayuda a organizar adecuadamente la información de los fenómenos y a determinar las leyes que los rigen.	Comprende: recuento y compilación de datos, tabulación y agrupamiento, representación gráfica, medición de datos, inferencia estadística y predicción.
Estudio sistemático, controlado, empírico y crítico de proposiciones hipotéticas acerca de presuntas relaciones de varios fenómenos.	Secuencia de procedimientos para el manejo de los datos cualitativos y cuantitativos de la investigación.

Capítulo 3

Clase 3

3.1. Estructura y Fuentes de los Datos

3.1.1. Datos

Los datos son las observaciones recolectadas (como mediciones, géneros, respuestas de encuesta). Se recogen, analizan y resumen para su presentación e interpretación. A todos los datos reunidos para un determinado estudio se les llama **conjunto de datos** para el estudio.

Cuadro 3.1:

Sexo	Nivel de estudio	Años de estudio	Medio pref.	Ingresos (S.M)	Edad	Estatura	Estrato
F	Pregrado	16	Prensa	1.0	23	1.64	3
M	Bachiller	13	TV	1.5	23	1.65	4
M	Bachiller	12	Radio	1.0	23	1.60	3
M	Pregrado	18	Prensa	2.5	51	1.57	3
M	Media-Básica	10	TV	1.0	19	1.77	2

3.1.2. Fuentes de Datos

Las fuentes de datos pueden clasificarse de la siguiente manera:

- **Registros rutinarios:** Hospitales, registros contables, entre otros.
- **Encuestas:** Se recurre a ellas cuando no hay registros almacenados.
- **Experimentación:** Resultados de un diseño experimental.

- **Fuentes externas:** Publicaciones de instituciones.

En ocasiones, los datos no pueden obtenerse de las fuentes existentes y deben generarse mediante la realización de un estudio estadístico. Estos datos se clasifican como **experimentales** u **observacionales**.

3.1.3. Variable

Una **variable** es una característica de los elementos que es de interés para el estudio. Un conjunto de datos puede contener múltiples variables. Por ejemplo, en la tabla anterior se identifican variables como sexo, nivel de estudio, años de estudio, medio de comunicación preferido, ingresos, edad, estatura y estrato socioeconómico.

3.1.4. Elementos

Los **elementos** son las entidades de las que se obtienen los datos. En un conjunto de datos, los nombres o identificadores de los elementos aparecen como referencia de cada observación registrada.

3.2. Datos de Sección Transversal y de Series de Tiempo

Para los propósitos del análisis estadístico, la distinción entre datos transversales y datos de series de tiempo es importante.

3.2.1. Datos de Sección Transversal

Los datos de sección transversal son los obtenidos en el mismo o aproximadamente el mismo momento (punto en el tiempo). Por ejemplo, una tabla que describe múltiples variables de varios individuos en un mismo instante constituye un conjunto de datos transversales.

3.2.2. Datos de Series de Tiempo

Los datos de series de tiempo son datos obtenidos a lo largo de varios periodos. Los economistas, por ejemplo, utilizan este tipo de datos para identificar tendencias.

3.3. Errores en la Adquisición de Datos

Usar datos erróneos es peor que no usar ningún dato. Un **error** ocurre cuando el dato obtenido no es igual al verdadero valor.

3.3.1. Tipos de Errores

- Error de escritura: registrar 24 años en lugar de 42 años.
- Malinterpretación de la pregunta por parte del entrevistado, lo que genera una respuesta incorrecta.

Se debe tener sumo cuidado tanto al recolectar los datos como al registrarlos para garantizar que no se cometan errores.

3.3.2. Verificación de Consistencia

Es necesario verificar la consistencia interna de los datos. Por ejemplo, un entrevistado con 24 años no puede tener 20 años de experiencia laboral. Se deben revisar datos que tengan valores inusualmente grandes o pequeños, denominados **observaciones atípicas**, que son candidatos a posibles errores.

3.4. Razones Prácticas para Utilizar una Muestra

Aunque un censo proporciona información de todos los miembros de una población, no siempre es viable realizarlo. El uso de una muestra puede reducir los costos y el tiempo requerido para el estudio, además de permitir un mayor control durante la obtención de los datos. En algunas situaciones, el muestreo es la única alternativa práctica debido a que:

- La población es tan grande que excede las posibilidades del investigador, tanto económicas como por limitaciones temporales.
- La población es suficientemente homogénea para estudiar una fracción de ella sin censar todos sus elementos.
- El proceso de medida o investigación es destructivo, como ocurre al consumir un cierto artículo para juzgar su calidad.

La principal limitación es la variabilidad muestral: dos muestras obtenidas de una misma población pueden producir resultados diferentes. Por esta razón, el alcance de las conclusiones debe considerar el tamaño de la muestra y la precisión requerida por el estudio.

3.5. Pensamiento Crítico ante la Estadística

3.5.1. Usos Inadecuados de la Estadística

Por lo general, existen dos situaciones en que la estadística se utiliza como fuente de engaño:

1. El intento malintencionado por parte de individuos deshonestos.
2. Errores no intencionales por parte de personas que no dominan la disciplina.

3.5.2. Gráficas y su Uso Inadecuado

Las gráficas pueden distorsionar la percepción de los datos si no se construyen correctamente. Se debe verificar que las escalas sean adecuadas y que no se exageren diferencias.

3.5.3. Resultados Reportados

Cuando se obtienen datos de personas, es mejor tomar las medidas directamente en lugar de pedir a los sujetos que reporten resultados. Las personas tienden a redondear, generalmente hacia abajo, y en temas como ingresos tienden a mentir.

3.5.4. Otros Aspectos a Considerar

- Uso adecuado de porcentajes.
- Preguntas que inducen respuestas sesgadas.
- Orden de las preguntas en una encuesta.
- Falta de respuesta por parte de los encuestados.
- Datos faltantes.
- Estudios realizados para el propio beneficio del investigador.
- Números precisos que pueden ser falsos.
- Distorsiones deliberadas.

3.6. Recolección de Datos Muestrales

3.6.1. Fundamentos de la Recolección de Datos

Los métodos estadísticos se rigen por los datos recabados. Por lo regular, se obtienen datos de dos fuentes distintas:

Cuadro 3.2:

Estudio observacional	Se observan y miden características específicas, pero no se intenta modificar a los sujetos que se están estudiando.
Experimento	Se aplican algunos tratamientos y luego se procede a observar sus efectos sobre los sujetos. Los sujetos se denominan <i>unidades experimentales</i> .

3.6.2. Estudios Retrospectivos y Prospectivos

Cuadro 3.3:

Estudio retrospectivo (de control de caso)	Los datos se toman del pasado (mediante examen de registros, entrevistas y otros recursos).
Estudio prospectivo (longitudinal o de cohorte)	Los datos se reunirán en el futuro y se toman de grupos (cohorte) que comparten factores comunes.

3.7. Estructura de un Conjunto de Datos

Un conjunto de datos puede organizarse de diversas formas. Una estructura común es la tabla bidireccional, donde las filas representan elementos (o categorías) y las columnas representan variables. Por ejemplo:

Cuadro 3.4:

	Prensa	Radio	TV
Varón	30	40	90
Mujer	25	35	75

De manera más general, si se tienen i niveles de estudio, j medios de comunicación preferido y k categorías de sexo, los datos se pueden organizar en una estructura tridimensional donde cada celda (i, j, k) contiene la frecuencia correspondiente.

3.8. Pensamiento Estadístico

3.8.1. Concepto Clave

Al finalizar el estudio introductorio de la estadística, el estudiante cuenta con numerosas herramientas analíticas. Sin embargo, efectuar cálculos sin considerar aspectos generales importantes equivale a estar “equipado peligrosamente”. El pensamiento estadístico exige que, antes de cualquier análisis formal, se tomen en cuenta factores fundamentales que determinan la validez y utilidad de los resultados.

Para aprender a pensar en términos estadísticos, suelen ser más importantes el sentido común y las consideraciones prácticas que la aplicación irreflexiva de fórmulas y cálculos. Para analizar de forma adecuada unos datos, es necesario contar con información adicional que proporcione el contexto adecuado.

Las preguntas fundamentales que guían el pensamiento estadístico son:

- ¿Cuál es el contexto de los datos?
- ¿De qué fuente se obtuvieron?
- ¿Cómo se recabaron?
- ¿Qué se puede concluir a partir de la información?
- Con base en conclusiones estadísticas, ¿qué implicaciones prácticas resultan del análisis?

3.8.2. Contexto y Fuente de los Datos

Siempre se debe tomar en cuenta el contexto de los datos, ya que este determina el análisis estadístico que debe emplearse. El contexto incluye la naturaleza de las variables, las unidades de medición y el propósito del estudio.

Respecto a la fuente, es necesario considerar si esta es objetiva o si existe alguna razón para pensar que está sesgada. No todos los estudios cuentan con fuentes sin sesgo. Se debe permanecer atento y escéptico ante estudios que provienen de fuentes que podrían tener intereses particulares en obtener ciertos resultados.

3.8.3. Método de Muestreo

Al reunir datos muestrales para un estudio, el método de muestreo elegido puede afectar de manera importante la validez de las conclusiones. Un aspecto crítico es que las muestras de respuesta voluntaria (o autoseleccionadas) a menudo están sesgadas, ya que es más probable que los individuos con un interés especial en el tema decidan participar. En una muestra de respuesta voluntaria, los propios sujetos deciden participar, y aunque es posible utilizar métodos estadísticos válidos para analizarlas, los resultados no son necesariamente válidos.

3.8.4. Conclusiones e Implicaciones Prácticas

Al obtener conclusiones a partir de un análisis estadístico, es necesario formular afirmaciones que sean claras para personas sin conocimientos de estadística ni de su terminología. Se debe evitar cuidadosamente realizar afirmaciones que no estén justificadas por el análisis estadístico.

Además de plantear conclusiones claras, también se deben identificar las implicaciones prácticas de los resultados. Una conclusión puede ser estadísticamente correcta pero carecer de relevancia práctica, o viceversa.

3.8.5. Significancia Estadística y Significancia Práctica

La significancia estadística de un estudio difiere de su significancia práctica. Es posible que, con base en los datos muestrales disponibles, se utilicen métodos estadísticos para llegar a la conclusión de que algún tratamiento o hallazgo es eficaz, aunque el sentido común sugiera que la diferencia no es suficiente para justificar su uso práctico.

En términos formales, la significancia estadística se alcanza cuando la probabilidad de obtener el resultado observado por puro azar es muy pequeña. Un criterio común es que se logra significancia estadística si dicha probabilidad es del 5 % o menos:

$$P(\text{resultado por azar}) \leq 0,05$$

Sin embargo, un resultado estadísticamente significativo no necesariamente tiene significancia práctica. Por ejemplo, si un tratamiento aumenta la probabilidad de un evento del 50 % al 52 %, el resultado puede ser estadísticamente significativo con una muestra suficientemente grande, pero la diferencia práctica es mínima.

3.8.6. Definición de Pensamiento Estadístico

El pensamiento estadístico incluye el pensamiento crítico y la capacidad de interpretar los resultados. También puede implicar determinar si los resultados son estadísticamente significativos. El pensamiento estadístico va mucho más allá de la simple capacidad de ejecutar cálculos complejos; implica la capacidad de observar el panorama general, tomar en cuenta factores relevantes como el contexto, la fuente de los datos y el método de muestreo, obtener conclusiones e identificar implicaciones prácticas.

3.9. Tipos de Datos

3.9.1. Parámetro y Estadístico

Es importante distinguir entre parámetro y estadístico. Los primeros son cantidades constantes que describen una población; los segundos dependen de la muestra extraída y varían de una muestra a otra.

- **Parámetro:** es cualquier cantidad constante que describe una característica de la población (por ejemplo, la media poblacional μ o la proporción poblacional p).
- **Estadístico:** es cualquier función de las variables aleatorias que constituyen una muestra extraída de la población (por ejemplo, la media muestral $\bar{x}$ o la proporción muestral $\hat{p}$).

La notación habitual asocia parámetros con letras griegas y estadísticos con letras latinas:

Parámetros poblacionales: μ , σ , p Estadísticos muestrales: $\bar{x}$, s , $\hat{p}$

3.9.2. Datos Cuantitativos

Los datos cuantitativos (o numéricos) consisten en números que representan conteos o mediciones. Se subdividen en dos categorías:

- **Datos discretos:** resultan cuando el número de posibles valores es finito o contable. Suelen tomar valores enteros y existe separación o interrupción entre valores consecutivos. Ejemplos: número de hijos, cantidad de automóviles, número de defectos en un lote.
- **Datos continuos:** resultan de un infinito de posibles valores que pueden asociarse a puntos de una escala continua, cubriendo un rango sin huecos ni interrupciones. Pueden tomar cualquier valor dentro de un intervalo. Ejemplos: estatura, peso, temperatura, tiempo de reacción.

3.9.3. Datos Cualitativos

Los datos cualitativos (también llamados categóricos o de atributo) se dividen en diferentes categorías que se distinguen por alguna característica no numérica. No se pueden medir numéricamente de forma directa. Ejemplos: nivel de estudios, género, religión, raza, estrato socioeconómico, nacionalidad, color de la piel.

3.9.4. Niveles de Medición

Otra forma de clasificar los datos consiste en usar cuatro niveles de medición. Cuando se aplica la estadística a problemas reales, el nivel de medición de los datos es un factor importante para determinar el procedimiento estadístico adecuado.

Nivel nominal. Los datos consisten exclusivamente en nombres, etiquetas o categorías cuyos valores solo poseen la propiedad de identidad ($a = a$, $a \neq b$). No se pueden organizar en un esquema de orden ni realizar operaciones aritméticas con ellos. Ejemplo: color de ojos, género, ciudad de residencia.

Nivel ordinal. Los datos pueden acomodarse en algún orden o jerarquía, existe transitividad ($a < b$ y $b < c$ implica $a < c$), aunque no es posible determinar diferencias entre los valores o tales diferencias carecen de significado. Ejemplo: clasificaciones de universidades, nivel de satisfacción (bajo, medio, alto).

Nivel de intervalo. En contraste con el nivel ordinal, esta escala tiene diferencias precisas entre unidades de medida. Establece un orden en las posiciones relativas y la diferencia entre dos valores cualesquiera tiene significado. Sin embargo, no posee un punto de partida cero inherente (natural); el cero es relativo y arbitrario, por lo que las razones no tienen sentido. Por ejemplo, una temperatura de 0°C no indica ausencia de temperatura, y no es válido afirmar que 50°F es el doble de temperatura que 25°F . Un coeficiente intelectual de 0 no implica ausencia de inteligencia.

Nivel de razón. Posee todas las características del nivel de intervalo, con la propiedad adicional de un punto de partida cero inherente donde cero indica que nada de la cantidad está presente. Para valores en este nivel, tanto las diferencias como las proporciones tienen significado. Ejemplos: peso (60 kg es un 20 % más pesado que 50 kg), distancia, tiempo, edad. El cero absoluto o natural representa la nulidad de lo que se estudia.

Una regla práctica para distinguir entre nivel de intervalo y nivel de razón es considerar si la expresión “dos veces” tiene sentido: si una cantidad es el doble de la otra y esta afirmación es

válida, se aplica el nivel de razón; en caso contrario, se aplica el nivel de intervalo.

Capítulo 4

Clase 4

4.1. Pensamiento Crítico y Comunicación Estadística

La presentación de resultados estadísticos debe permitir que el lector evalúe la información sin inducir interpretaciones engañosas. Los usos inadecuados pueden originarse tanto en manipulaciones deliberadas como en errores cometidos por desconocimiento.

4.1.1. Distorsiones en las Gráficas

Una gráfica puede exagerar u ocultar diferencias aun cuando los valores representados sean correctos. Para evaluar una representación gráfica se deben revisar, como mínimo, los siguientes aspectos:

- El origen, la escala y los intervalos de los ejes.
- La correspondencia entre el tamaño de los elementos gráficos y las cantidades representadas.
- El uso de figuras tridimensionales para datos que solo requieren una dimensión.
- El periodo seleccionado y la posible omisión de observaciones relevantes.
- La presencia de títulos, unidades y etiquetas suficientes para interpretar la gráfica.

Un eje vertical truncado puede hacer que una diferencia pequeña parezca considerable. Del mismo modo, representar cantidades mediante áreas o volúmenes puede deformar su comparación si las dimensiones de las figuras no se ajustan proporcionalmente.

4.1.2. Resultados Autoinformados

Cuando sea posible, las variables deben medirse directamente. Los datos declarados por los participantes pueden contener redondeos, fallos de memoria o respuestas deliberadamente inexactas, especialmente en temas sensibles como ingresos, hábitos o antecedentes personales.

La interpretación también debe considerar preguntas que inducen una respuesta, el orden del cuestionario, la falta de respuesta, los datos faltantes, los conflictos de interés y la presentación de cifras con una precisión mayor que la permitida por el método de medición.

4.1.3. Lista de Verificación para Interpretar Resultados

Antes de aceptar una conclusión estadística conviene comprobar:

1. Si la fuente y el propósito del estudio están claramente identificados.
2. Si las unidades, escalas y tamaños muestrales están informados.
3. Si la representación gráfica es proporcional y utiliza el contexto completo.
4. Si las conclusiones se limitan a lo que permiten los datos y el diseño del estudio.
5. Si se distinguen la precisión numérica, la incertidumbre y la relevancia práctica.

4.2. Muestreo Probabilístico y Diseños Multietápicos

4.2.1. Muestreo Probabilístico

En un diseño probabilístico, cada elemento de la población posee una probabilidad conocida y mayor que cero de ser seleccionado. Esta propiedad permite calcular ponderaciones y cuantificar la incertidumbre asociada a las estimaciones.

La probabilidad de inclusión no tiene que ser igual para todos los elementos. Cuando las probabilidades son diferentes, cada observación puede recibir un peso que compense su mayor o menor posibilidad de formar parte de la muestra.

4.2.2. Muestreo Multietápico

El muestreo multietápico selecciona unidades de manera sucesiva y combina varios procedimientos. Por ejemplo, un estudio educativo nacional podría seguir estas etapas:

Cuadro 4.1:

Etapas	Unidad seleccionada	Procedimiento
1	Municipios	Seleccionar municipios de distintas regiones.
2	Instituciones	Elegir instituciones dentro de cada municipio seleccionado.
3	Estudiantes	Seleccionar estudiantes dentro de cada institución elegida.

Este diseño reduce costos y facilita el trabajo de campo en poblaciones extensas. Sin embargo, el análisis debe considerar todas las etapas de selección, pues tratar los datos como si procedieran de una muestra aleatoria simple puede subestimar la incertidumbre.

4.3. Organización de Datos Multidimensionales

4.3.1. Matriz de Datos

Un conjunto de datos puede representarse mediante una matriz

$$X = (x_{ij}), \quad i = 1, \dots, n, \quad j = 1, \dots, p,$$

donde cada fila corresponde a una unidad de observación, cada columna representa una variable y x_{ij} es el valor de la variable j observado en la unidad i . Esta organización facilita el análisis simultáneo de varias características.

4.3.2. Tablas de Contingencia

Cuando las variables son categóricas, sus combinaciones pueden resumirse en tablas de contingencia. Cada celda contiene la frecuencia correspondiente a una combinación de categorías. Las sumas por filas o columnas se denominan **frecuencias marginales**, mientras que las proporciones calculadas dentro de una fila o columna describen **distribuciones condicionales**.

4.3.3. Relaciones entre Varias Variables

En un conjunto multidimensional, una relación observada entre dos variables puede cambiar al incorporar una tercera. Por ello, además de examinar asociaciones globales, conviene comparar grupos y estudiar posibles interacciones. La organización multidimensional permite identificar patrones que no son visibles en resúmenes de una sola variable.

Capítulo 5

Clase 5

5.1. Descripción, exploración y comparación de datos

5.1.1. Introducción y características de los datos

El análisis de conjuntos de datos extensos requiere organizar, resumir y representar la información de una forma conveniente y significativa, lo cual corresponde al ámbito de la Estadística Descriptiva. Los datos se pueden resumir de forma numérica en tablas o de forma visual en gráficas, dependiendo de la naturaleza de los datos. El objetivo principal no es solo generar una tabla o gráfica, sino analizar y comprender lo que estos indican sobre la distribución y características generales del conjunto.

Las características importantes que se deben evaluar en los datos son:

- **Centro:** Valor representativo o promedio que indica la localización de la mitad del conjunto de los datos.
- **Variación:** Medida de la cantidad en que los valores de los datos varían entre sí.
- **Distribución:** Naturaleza o forma de la distribución de los datos (por ejemplo, forma de campana).
- **Datos distantes (Atípicos):** Valores muestrales que están muy alejados de la vasta mayoría de los demás valores de la muestra.
- **Tiempo:** Características cambiantes de los datos a través del tiempo.

5.1.2. Distribuciones de frecuencias

Una distribución de frecuencias (o tabla de frecuencias) es una herramienta fundamental cuando se trabaja con conjuntos grandes de datos. Consiste en listar los distintos valores posibles de los datos (ya sea de forma individual o agrupados en intervalos) junto con sus frecuencias correspondientes,

es decir, el número de veces que ocurren dichos valores.

A continuación, se presentan ejemplos de tablas de frecuencias para datos categóricos y cuantitativos agrupados:

Cuadro 5.1:

Estado Civil	Frecuencia (f_i)
Casada	100
Soltera	56
Sep/Div	30
Viuda	14
Total	200

Cuadro 5.2:

Niveles de Cotinina	Frecuencia (f_i)
0–99	11
100–199	12
200–299	14
300–399	1
400–499	2

Conceptos básicos de las clases

Para datos cuantitativos agrupados, se definen los siguientes elementos:

- **Límites de clase inferiores y superiores:** Son las cifras más pequeñas y más grandes, respectivamente, que pueden pertenecer a las diferentes clases.
- **Fronteras de clase:** Cifras utilizadas para separar las clases sin dejar espacios vacíos entre ellas.
- **Marcas de clase (c_i):** Son los puntos medios de las clases.
- **Anchura de clase:** La diferencia entre dos límites de clase inferiores consecutivos.

5.1.3. Procedimiento de construcción para datos cuantitativos

Para construir una distribución de frecuencias de manera sistemática, se siguen los siguientes pasos matemáticos:

1. **Elegir el número de intervalos (k):** Generalmente entre 5 y 20 clases de igual tamaño. Se pueden utilizar criterios como la raíz cuadrada del número de datos, la ley de Sturges:

$$k = 1 + 3,322 \log n$$

O el criterio alternativo:

$$k \leq 5 \log n$$

2. **Hallar el rango de los datos (R):**

$$R = x_{\text{máx}} - x_{\text{mín}}$$

3. **Definir el tamaño o longitud del intervalo de clase (h):**

$$h \approx \frac{R}{k}$$

De modo que $h \cdot k \geq R$ (Rango ajustado).

4. **Establecer las fronteras y límites:** Las fronteras de clase suelen ser cerradas al lado izquierdo. Los límites no deben ser ambiguos ni coincidir con valores posibles de los datos (se recomienda usar una cifra decimal más).

Tipos de frecuencias

Dado un conjunto de n observaciones, para cada intervalo i se calculan:

- n_i : Frecuencia absoluta (conteo de datos en el intervalo).
- N_i : Frecuencia acumulada en cada intervalo.
- $f_i = \frac{n_i}{n}$: Frecuencia relativa.
- $F_i = \frac{N_i}{n}$: Frecuencia relativa acumulada.
- c_i : Marca de clase (punto medio del intervalo).

La estructura general de la tabla resultante es la siguiente:

Cuadro 5.3:

Intervalo	Lím. Inf.	Lím. Sup.	c_i	N_i	n_i	F_i	f_i
1: $[\cdot, \cdot)$							
2: $[\cdot, \cdot)$							

Continued on next page

Cuadro 5.3: (Continued)

Intervalo	Lím. Inf.	Lím. Sup.	c_i	N_i	n_i	F_i	f_i
$\vdots$							
$k: [\cdot, \cdot)$							

5.1.4. Implementación tecnológica

Construcción en Excel

Para automatizar el proceso en hojas de cálculo, se utilizan las siguientes funciones y atajos:

```
n: Número de observaciones =contar()
Máximo =Max()
Mínimo =Min()
Rango R= Max()-Min()
K:# de intervalos k= 1+ 3.322 log n
Amplitud R/K
Frecuencias =Frecuencia(datos; límites superiores)
```

Nota: La instrucción de frecuencia se aplica en la primera casilla y se propaga al resto seleccionando las casillas, yendo a la barra de funciones y ejecutando CTRL + +. Para las etiquetas de intervalos se puede usar:

```
=CONCATENA("(";lim inf;"-";lim sup;"]")
```

Para el gráfico de barras (histograma), se señalan las marcas de clase y frecuencias, se inserta el gráfico de barras, y en el formato de la serie de datos se establece el ancho de barra en “0” para que queden adyacentes.

Construcción en R

Utilizando la librería *agricolae* para tablas de frecuencia:

```
install.packages(agricolae) # Instalamos librería
library(agricolae)         # Descargamos la librería
Datos                      # Llamamos los datos
Variable5<-Datos$Variable5 # Extraemos la variable
Variable5
attach(Datos)              # Desagregamos la base de datos
listaVariable5<-hist(Variable5, plot=FALSE)
tablafq<-table.freq(listaVariable5)
```

5.1.5. Histogramas y Distribución Normal

El histograma de frecuencias es el método gráfico más utilizado para datos cuantitativos. Consiste en un conjunto de rectángulos con bases en el eje x , centrados en la marca de clase, con longitudes iguales a los intervalos de clase y áreas (o alturas, si la anchura es constante) proporcionales a las frecuencias.

Cuadro 5.4:

Intervalo	Frecuencia Absoluta
[158, 159,5)	1
[159,5, 161)	15
[161, 162,5)	15
[162,5, 164)	33
[164, 165,5)	50
[165,5, 167)	35
[167, 168,5)	27
[168,5, 170)	14
[170, 172)	0

Un **histograma de frecuencias relativas** mantiene la misma forma y escala horizontal, pero la escala vertical se marca con proporciones o porcentajes, lo cual es preferible para fines comparativos.

Distribución Normal

Las distribuciones de frecuencias pueden revelar la naturaleza de los datos. Una distribución normal (o en forma de campana) se caracteriza por:

1. Al inicio las frecuencias son bajas, después se incrementan hasta un punto máximo y luego disminuyen.
2. La distribución es aproximadamente simétrica; las frecuencias tienden a distribuirse de manera uniforme a ambos lados de la frecuencia máxima, como una imagen en un espejo.

5.1.6. Otras técnicas visuales y gráficas

Gráfica de Pareto

Es una gráfica de barras para datos cualitativos donde las barras se ordenan de mayor a menor frecuencia (de izquierda a derecha). Las escalas verticales pueden representar frecuencias absolutas o relativas. Es útil para resaltar las categorías más importantes.

Cuadro 5.5:

Nivel de Estudios	Frecuencia
Bachiller	89
Pregrado	80
Técnica	68
Básica	62
Postgrado	28

Implementación en R para gráficas de Pareto:

```
install.packages('qcc')
library(qcc)
TablaVarCategorica<- table(VarCategorica)
pareto.chart(TablaVarCategorica)
```

Polígonos de frecuencias

Se obtienen graficando los puntos (c_i, n_i) , donde c_i es la marca de clase y n_i la frecuencia correspondiente, uniendo dichos puntos con segmentos de recta. Es usual cerrar los polígonos agregando líneas en los extremos hasta que toquen el eje horizontal. Sugieren curvas de frecuencias continuas y suaves.

Gráficas circulares

Presentan datos cualitativos como rebanadas de un pastel, donde el tamaño (ángulo) de cada rebanada es proporcional al conteo de frecuencia de la categoría.

Diagrama de tallos y hojas (Stem-and-Leaf)

Técnica que divide cada valor numérico en dos partes: el “tallo” (dígito principal) y la “hoja” (dígito secundario). Los tallos se disponen en el eje vertical y las hojas en el horizontal. Tiene la ventaja de mostrar la forma de la distribución conservando los valores originales de los datos.

5.1.7. Formas de las curvas de frecuencias

Las curvas de frecuencias pueden asumir diversas formas:

- **Simétricas (Campana):** Las observaciones equidistantes del máximo central tienen la misma frecuencia (ej. Distribución Normal).
- **Sesgadas a la derecha (Sesgo positivo):** No tienen simetría; la cola al lado derecho del máximo central es más larga (ej. Distribución Chi-cuadrado).
- **Sesgadas a la izquierda (Sesgo negativo):** La cola al lado izquierdo del máximo central es más larga.

5.1.8. Diagramas de dispersión y gráficas de puntos

- **Diagramas de dispersión:** Gráfica de datos apareados (x, y) con un eje horizontal x y un eje vertical y . Cada valor de un conjunto corresponde a un valor de un segundo conjunto, permitiendo visualizar la relación entre dos variables.
- **Gráficas de puntos:** Consiste en marcar cada valor de un dato como un punto a lo largo de una escala de valores unidimensional. Los puntos que representan valores iguales se amontonan o apilan verticalmente.