Notas de clase

Fundamentos de Estadística I

Semestre 2026-2

Instituto de Matemáticas, Universidad de Antioquia

Autor: Daniel Soto Villada

6 de noviembre de 2026

Índice general

1. Clase 1: Introducción a la regresión lineal **2**
- 1.1. Motivación: explicar y predecir . . . 2
- 1.2. Variable respuesta y variables predictoras . . . 3
- 1.3. Preguntas iniciales sobre la relación entre variables . . . 3
- 1.4. Regresión simple: un ejemplo con calificaciones . . . 3

2. Clase 2: Modelo de regresión lineal simple **5**
- 2.1. De la asociación a la regresión . . . 5
- 2.2. Modelo lineal con error aleatorio . . . 5
  - 2.2.1. Supuestos sobre el error . . . 6
- 2.3. La recta estimada y los residuos . . . 6
  - 2.3.1. Criterio de mínimos cuadrados . . . 7
- 2.4. Fórmulas de la recta de mínimos cuadrados . . . 7
  - 2.4.1. Cálculo con las calificaciones del ejemplo . . . 8
- 2.5. Covarianza y signo de la pendiente . . . 8
- 2.6. Diagnóstico del modelo mediante residuos . . . 9
- 2.7. Correlación y tipos de dependencia . . . 10
- 2.8. Ecuaciones y tipos de regresión . . . 11
- 2.9. Supuestos que fundamentan la inferencia . . . 12
  - 2.9.1. Significado de los coeficientes . . . 12
- 2.10. Representatividad de la recta y variación residual . . . 12
  - 2.10.1. Descomposición de la variación . . . 13
- 2.11. Coeficiente de determinación . . . 14

Capítulo 1

Clase 1: Introducción a la regresión lineal

1.1. Motivación: explicar y predecir

En muchos estudios interesa describir cómo cambia una característica de interés en relación con otras variables. Por ejemplo, estudiantes, familias y universidades pueden preguntarse si es posible anticipar el promedio académico (GPA) al terminar el primer año universitario, usando información disponible antes del ingreso.

Para hacer una predicción podrían considerarse variables como el puesto del estudiante en su grupo de secundaria, el nivel general de su colegio, sus calificaciones previas y el resultado de una prueba de admisión. Estas variables no determinan el resultado de manera exacta; aportan información que puede ayudar a describir su comportamiento promedio.

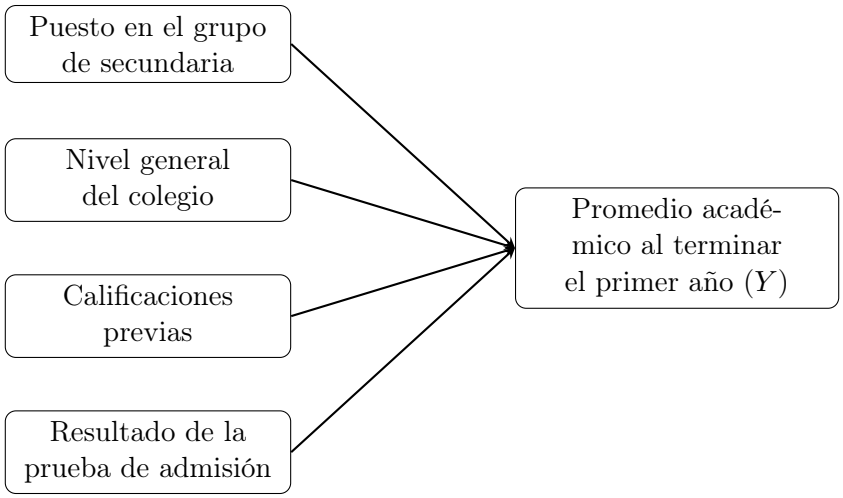


Figura 1.1: Esquema de algunas variables que podrían usarse para anticipar el promedio académico.

La pregunta general es cómo resumir la relación entre una variable de interés y la información disponible, y qué tan útil resulta esa relación para predecir. Los modelos de regresión ofrecen un marco para estudiar estas preguntas.

1.2. Variable respuesta y variables predictoras

Llamaremos Y a la **variable respuesta** o dependiente, cuyo comportamiento queremos describir o predecir. Las variables $X_1, \ldots, X_m$ se denominan **predictoras** o independientes en el sentido del modelo: son la información que se utiliza para estudiar la respuesta. Esta denominación señala el papel de las variables dentro del modelo; no implica independencia probabilística. En esta introducción consideraremos variables cuantitativas.

El análisis de regresión se centra en describir el tipo de relación entre las variables y en usar los valores de las predictoras para estimar el valor medio esperado de Y. La notación

$$\mathbb{E}(Y \mid X_1 = x_1, \ldots, X_m = x_m)$$

representa ese promedio de la respuesta para valores determinados de las predictoras.

Cuando se utiliza una relación lineal, las formas generales se escriben así:

$$\begin{aligned} \text{Regresión lineal simple:} \qquad & \mathbb{E}(Y \mid X = x) = \beta_0 + \beta_1 x, \\ \text{Regresión lineal múltiple:} \qquad & \mathbb{E}(Y \mid X_1 = x_1, \ldots, X_m = x_m) = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m. \end{aligned}$$

La regresión es **simple** cuando se considera una sola variable predictora y **múltiple** cuando se consideran varias. En esta clase, las expresiones solo presentan la estructura de los modelos; todavía no se estiman sus parámetros ni se evalúa su precisión.

1.3. Preguntas iniciales sobre la relación entre variables

Cuando se estudian dos variables cuantitativas, conviene plantear algunas preguntas antes de construir un modelo:

1. ¿Hay evidencia de que las variables estén relacionadas, o su comportamiento parece independiente?
2. Si hay relación, ¿qué forma tiene y qué tan marcada parece?
3. ¿Es posible predecir la variable respuesta a partir de la predictora? ¿Con qué precisión?

El análisis de correlación describe si existe asociación entre variables y su grado. El análisis de regresión estudia la forma de la relación y plantea cómo predecir una variable respuesta a partir de una o más predictoras. En los temas siguientes del curso se estudiarán con detalle distintas herramientas para responder estas preguntas.

1.4. Regresión simple: un ejemplo con calificaciones

Para ilustrar el caso simple, consideremos los datos de diez estudiantes de primer año de universidad que aparecen en el documento de referencia. Para cada estudiante se registró la calificación de un examen de Matemáticas y los puntos finales obtenidos en Cálculo. Definimos:

- X: calificación del examen de Matemáticas;
- Y: puntos finales en Cálculo.

Cada estudiante aporta un par de observaciones (x_i, y_i), pues ambas calificaciones corresponden a la misma persona.

Estudiantes 1–5		**Estudiantes 6–10**	
X**: Matemáticas**	Y**: Cálculo**	X**: Matemáticas**	Y**: Cálculo**
39	65	47	89
43	78	28	73
21	52	75	98
64	82	34	56
57	92	52	75

Cuadro 1.1: Calificaciones de Matemáticas y puntos finales en Cálculo de diez estudiantes.

Una manera inicial de observar la relación es representar los pares en un diagrama de dispersión. Cada punto del gráfico corresponde a un estudiante; su posición horizontal indica la calificación de Matemáticas y su posición vertical los puntos de Cálculo.

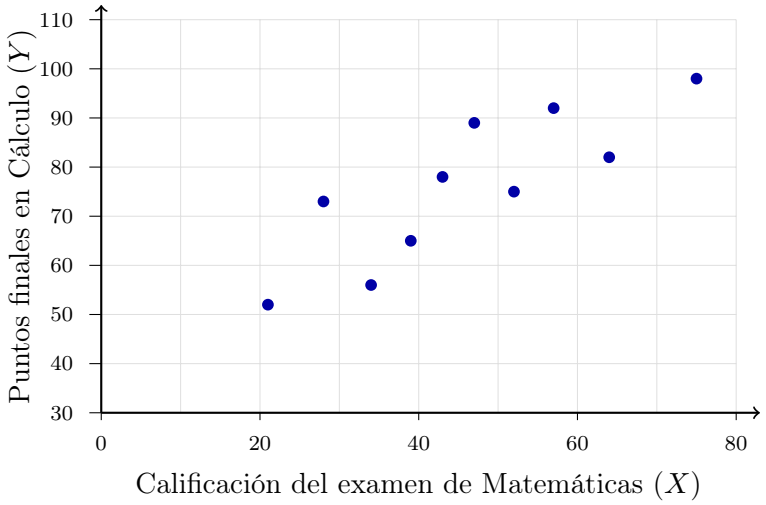


Figura 1.2: Diagrama de dispersión de las calificaciones de Matemáticas y Cálculo.

En estos datos se aprecia una tendencia creciente: en general, estudiantes con calificaciones más altas en el examen de Matemáticas también obtuvieron más puntos en Cálculo. Sin embargo, los puntos no siguen un patrón perfectamente exacto. El gráfico sirve como primera descripción visual de la asociación; por sí solo no determina una ecuación predictiva ni cuantifica su precisión.

Capítulo 2

Clase 2: Modelo de regresión lineal simple

2.1. De la asociación a la regresión

Al estudiar dos variables cuantitativas preguntamos si están relacionadas, cuál parece ser la forma y el grado de esa relación, y si una variable puede ayudar a predecir la otra. El análisis de correlación resume la asociación; la regresión describe una forma para el valor medio de una variable respuesta Y en función de una variable predictora X.

En esta clase retomamos el ejemplo de las calificaciones de Matemáticas y Cálculo presentado en la Clase 1. La nube de puntos muestra una tendencia creciente, aunque las observaciones no caen exactamente sobre una recta. Para representar esa variación introducimos un modelo probabilístico.

2.2. Modelo lineal con error aleatorio

La parte sistemática del modelo es una función lineal de X. Para una observación con valor predictor x, su respuesta promedio se representa por

$$\mathbb{E}(Y \mid X = x) = \alpha + \beta x,$$

donde α es la ordenada al origen y β es la pendiente de la recta de medias. La respuesta individual puede apartarse de ese promedio; por eso se incorpora un error aleatorio ε:

$$Y = \alpha + \beta X + \varepsilon.$$

Así, $\alpha + \beta x$ describe el nivel medio de la respuesta cuando $X = x$, mientras que ε representa la desviación de una observación particular respecto a ese promedio.

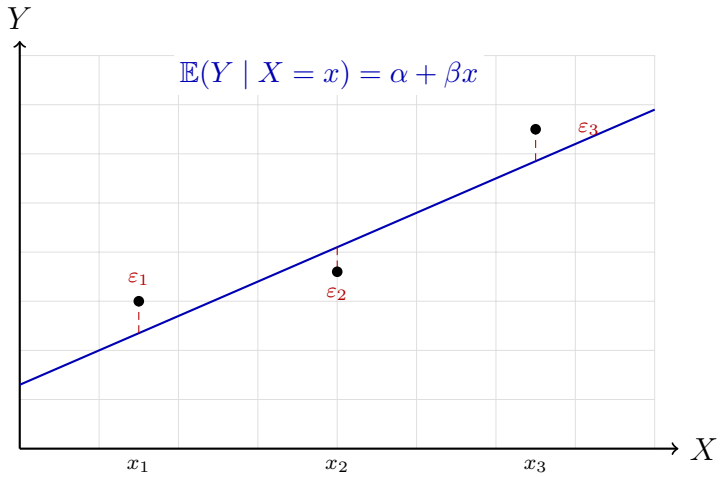


Figura 2.1: Esquema del modelo: las respuestas observadas se desvían de la recta de medias por el error aleatorio.

2.2.1. Supuestos sobre el error

Para el modelo clásico de regresión lineal simple se consideran los siguientes supuestos sobre los errores:

- los errores de observaciones distintas son independientes;
- su media es cero: $\mathbb{E}(\varepsilon_i) = 0$;
- tienen una varianza común $\mathrm{Var}(\varepsilon_i) = \sigma^2$;
- tienen distribución normal.

En particular, el supuesto de media cero hace que la recta $\alpha+\beta x$ coincida con la respuesta promedio para cada valor de x. La varianza común indica que la dispersión alrededor de la recta se supone similar a lo largo del rango de X. Estos supuestos describen el modelo y no garantizan que se cumplan para cualquier conjunto de datos.

2.3. La recta estimada y los residuos

En una muestra se desconocen los parámetros α y β. Se estiman con valores a y b, y se obtiene la recta ajustada

$$\widehat{y} = a + bx.$$

Para la observación i, el valor estimado es $\widehat{y}_i = a + bx_i$. La diferencia entre la respuesta observada y la estimada se llama **residuo**:

$$e_i = y_i - \widehat{y}_i.$$

El error ε_i del modelo es una cantidad aleatoria no observada; el residuo e_i se calcula después de ajustar la recta y sirve para describir la diferencia en los datos.

2.3.1. Criterio de mínimos cuadrados

Una recta puede quedar por encima de algunas observaciones y por debajo de otras. La suma simple de las diferencias con signo puede cancelarse; por eso se elige la recta minimizando la suma de los cuadrados de los residuos:

$$S(a,b) = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} \big(y_i - (a + bx_i)\big)^2.$$

El **método de mínimos cuadrados** escoge a y b de modo que $S(a,b)$ sea lo menor posible. Las distancias consideradas son verticales, pues para cada x_i se compara y_i con el valor de la recta en ese mismo punto.

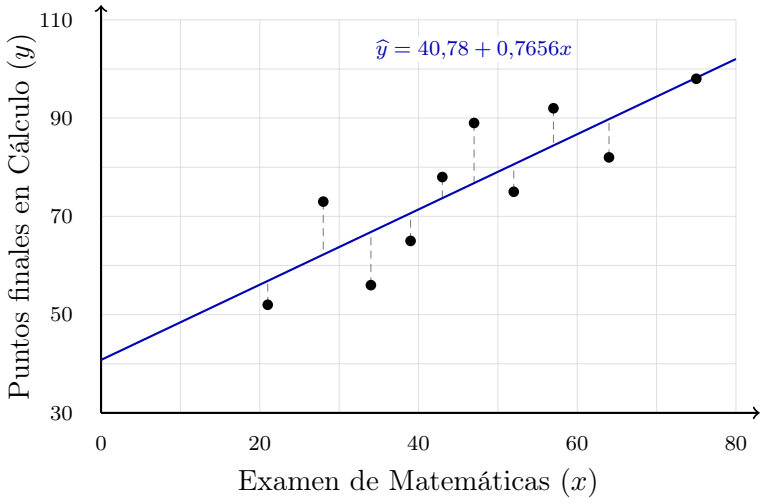


Figura 2.2: Recta ajustada al ejemplo y distancias verticales entre cada dato y su valor estimado.

2.4. Fórmulas de la recta de mínimos cuadrados

Sin desarrollar aquí el cálculo diferencial, las fórmulas para los estimadores de mínimos cuadrados son

$$b = \frac{s_{XY}}{s_X^2}, \qquad a = \bar{y} - b\bar{x},$$

donde $\bar{x}$ y $\bar{y}$ son los promedios muestrales, s_{XY} es la covarianza muestral entre X y Y, y s_X^2 es la varianza muestral de X. De manera equivalente, si se definen las sumas centradas

$$C_{XY} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}), \qquad C_{XX} = \sum_{i=1}^{n} (x_i - \bar{x})^2,$$

entonces

$$b = \frac{C_{XY}}{C_{XX}}, \qquad a = \bar{y} - b\bar{x}.$$

El parámetro b es la pendiente estimada: señala cuánto cambia $\widehat{y}$ cuando x aumenta una unidad. El valor a es la ordenada al origen de la recta estimada.

2.4.1. Cálculo con las calificaciones del ejemplo

La tabla de la Clase 1 contiene los diez pares observados. Para calcular la recta se necesitan también las sumas de cuadrados y productos:

Estudiante	x_i	y_i	x_i^2	$x_i y_i$
1	39	65	1521	2535
2	43	78	1849	3354
3	21	52	441	1092
4	64	82	4096	5248
5	57	92	3249	5244
6	47	89	2209	4183
7	28	73	784	2044
8	75	98	5625	7350
9	34	56	1156	1904
10	52	75	2704	3900
Suma	**460**	**760**	**23634**	**36854**

Cuadro 2.1: Cálculos auxiliares para ajustar la recta a los datos de calificaciones.

De la tabla se obtienen $\bar{x} = 460/10 = 46$ y $\bar{y} = 760/10 = 76$. Por tanto,

$$C_{XY} = \sum x_i y_i - n\bar{x}\bar{y} = 36854 - 10(46)(76) = 1894,$$
$$C_{XX} = \sum x_i^2 - n\bar{x}^{\,2} = 23634 - 10(46)^2 = 2474.$$

Así, la pendiente y la ordenada al origen son

$$b = \frac{1894}{2474} \approx 0{,}7656,$$
$$a = 76 - (0{,}7656)(46) \approx 40{,}78.$$

La recta estimada para estos datos es

$$\widehat{y} = 40{,}78 + 0{,}7656x.$$

Según esta recta, por cada punto adicional en el examen de Matemáticas, el valor estimado de los puntos finales en Cálculo aumenta aproximadamente 0,77 puntos. La interpretación corresponde a la recta ajustada y no significa que cada estudiante siga exactamente esa relación.

2.5. Covarianza y signo de la pendiente

La covarianza resume cómo varían conjuntamente las observaciones de X y Y. Una definición descriptiva es

$$S_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

También es usual definir la covarianza muestral con denominador $n-1$. En la fórmula de la pendiente se usan covarianza y varianza con el mismo denominador; por ello, el factor común se cancela y se obtiene $b = C_{XY}/C_{XX}$ en cualquiera de las dos convenciones.

Cada producto $(x_i - \bar{x})(y_i - \bar{y})$ es positivo cuando x_i e y_i están ambos por encima de sus promedios o ambos por debajo; es negativo cuando uno está por encima y el otro por debajo. El signo conjunto que predomina determina el signo de la covarianza. Como $C_{XX} > 0$ para una variable X no constante, la pendiente $b = C_{XY}/C_{XX}$ tiene el mismo signo que la covarianza:

- si $b > 0$, la relación lineal estimada es directa: valores mayores de X se asocian con valores mayores de Y;
- si $b < 0$, la relación lineal estimada es inversa: valores mayores de X se asocian con valores menores de Y.

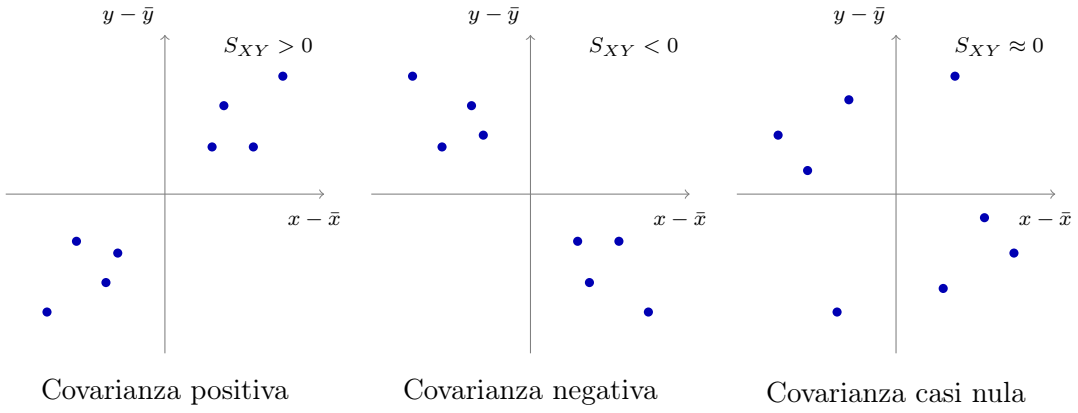


Figura 2.3: Patrones esquemáticos de los productos centrados y el signo de la covarianza.

En el ejemplo de calificaciones, $C_{XY} = 1894 > 0$ y $C_{XX} = 2474 > 0$, así que $b > 0$. Esto concuerda con la tendencia creciente observada en el diagrama de dispersión.

2.6. Diagnóstico del modelo mediante residuos

Las conclusiones de una regresión son confiables cuando los supuestos del modelo son razonables para los datos. Además de revisar el contexto y la forma de la nube de puntos, podemos estudiar los residuos. En el ejemplo de las calificaciones, la recta ajustada es $\widehat{y} = 40{,}78 + 0{,}7656x$; la siguiente tabla muestra los valores estimados y los residuos, redondeados a dos decimales.

Estudiante	y_i	$\widehat{y}_i$	$e_i = y_i - \widehat{y}_i$
1	65	70.64	−5,64
2	78	73.70	4.30
3	52	56.86	−4,86
4	82	89.78	−7,78
5	92	84.42	7.58
6	89	76.77	12.23
7	73	62.22	10.78
8	98	98.20	−0,20
9	56	66.81	−10,81
10	75	80.59	−5,59

Cuadro 2.2: Respuestas estimadas y residuos para los diez estudiantes.

En mínimos cuadrados con intercepto, la suma de los residuos es cero (salvo diferencias de redondeo en la tabla), de modo que su media muestral es cero. Para buscar patrones que indiquen problemas con los supuestos se utilizan varias gráficas:

- **Residuos contra orden de observación:** se revisa si aparecen tendencias, ciclos o agrupamientos. Un patrón puede ser indicio de que los errores no son independientes.
- **Residuos contra valores ajustados:** se espera una nube aleatoria alrededor de cero y con dispersión aproximadamente constante. Una curva puede indicar que la relación no es lineal; una forma de embudo puede indicar que la varianza cambia con el ajuste.
- **Gráfico Q–Q:** compara los residuos ordenados con los cuantiles teóricos de una distribución normal. Si la normalidad es plausible, los puntos suelen aproximarse a una línea creciente.

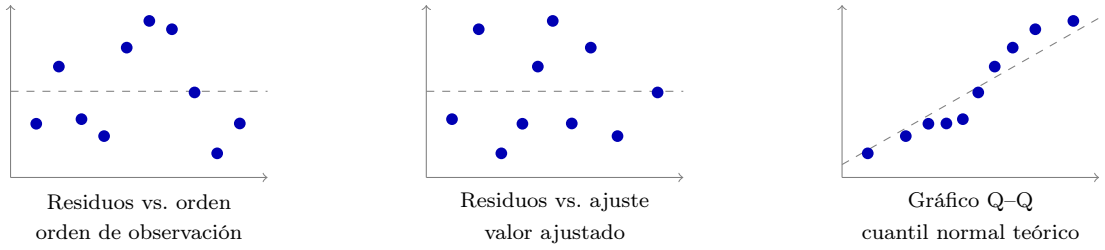


Figura 2.4: Esquemas de diagnóstico residual. En los dos primeros paneles se representan los residuos del ejemplo; en el Q–Q, su comparación con cuantiles normales aproximados.

En el gráfico Q–Q de este ejemplo no se aprecia una desviación marcada de la forma lineal. Esto no demuestra que los errores sean normales; con solo diez observaciones, el diagnóstico tiene alcance limitado.

Estas gráficas son herramientas de diagnóstico, no pruebas concluyentes. En particular, con una muestra pequeña conviene interpretarlas con cautela y junto con el conocimiento del problema.

2.7. Correlación y tipos de dependencia

El análisis de correlación se ocupa de medir la intensidad de la asociación entre dos variables; en este contexto nos interesa especialmente la asociación lineal. La covarianza vista antes ayuda a reconocer el sentido de la variación conjunta, mientras que el análisis de regresión busca representar la relación y estimar la respuesta a partir de la variable predictora.

Las relaciones entre X e Y pueden adoptar distintas formas. En una relación estadística, para un mismo valor de X puede haber variación en Y; la nube puede no mostrar un patrón claro, o mostrar una tendencia lineal o curvilínea. En una dependencia funcional, en cambio, cada valor de X determina exactamente un valor de Y, por lo que todos los puntos quedan sobre una curva.

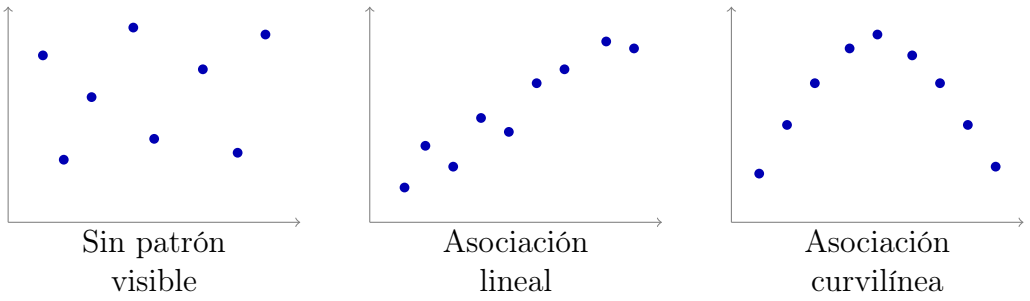


Figura 2.5: Ejemplos esquemáticos de ausencia de patrón visible y de asociaciones estadísticas lineal y curvilínea.

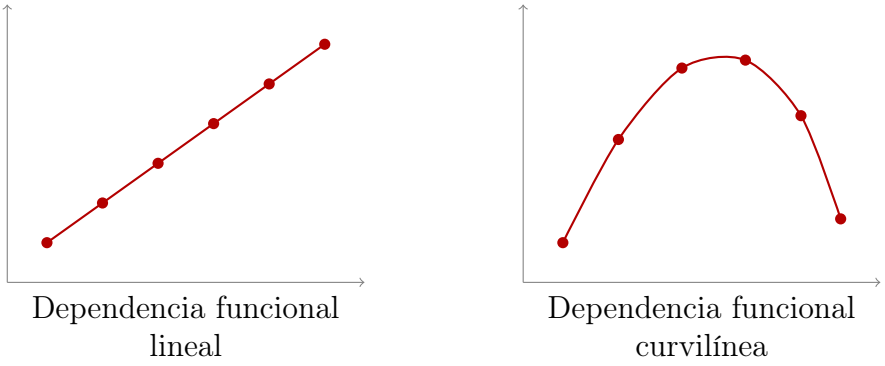


Figura 2.6: En una dependencia funcional, las observaciones siguen exactamente una relación lineal o curvilínea.

2.8. Ecuaciones y tipos de regresión

A la función que describe la respuesta en términos de la variable predictora se le llama **ecuación de regresión**. Algunos ejemplos son

$$\widehat{y} = a + bx \qquad \text{y} \qquad \widehat{y} = a + bx + cx^2.$$

La primera representa una recta; la segunda, una relación parabólica. También existen modelos curvilíneos de tipo exponencial o potencial. En una regresión lineal simple se utiliza una sola variable predictora y la ecuación es lineal en sus parámetros. Cuando se incluyen varias variables predictoras para una sola respuesta, se habla de regresión múltiple.

La forma de la nube de puntos ayuda a decidir qué tipo de relación podría describir los datos. En esta clase nos hemos concentrado en el caso simple lineal y en los conceptos de diagnóstico presentados en las páginas indicadas.

2.9. Supuestos que fundamentan la inferencia

Los supuestos ya presentados pueden precisarse para interpretar el modelo y realizar inferencias sobre sus parámetros. En el modelo clásico de regresión lineal simple se considera que:

1. los valores de X se fijan mediante el diseño del estudio. En otras aplicaciones, X puede ser aleatoria; el análisis se formula entonces condicionando en los valores observados de X;
2. X se mide con error despreciable;
3. para cada valor de X, la distribución condicional de Y es normal cuando se requieren los procedimientos usuales de inferencia;
4. la varianza condicional de Y es constante para todos los valores de X;
5. la media condicional de Y sigue una función lineal, $\mathbb{E}(Y \mid X = x) = \alpha + \beta x$;
6. las observaciones son independientes entre sí, condicionalmente a los valores de X.

Estos supuestos se resumen escribiendo, para cada observación,

$$Y_i = \alpha + \beta x_i + \varepsilon_i,$$

donde $\varepsilon_i = Y_i - \mathbb{E}(Y_i \mid X = x_i)$ es la desviación respecto de la media condicional. En particular,

$$\mathbb{E}(\varepsilon_i \mid X) = 0, \qquad \mathrm{Var}(\varepsilon_i \mid X) = \sigma^2,$$

y, bajo el supuesto de normalidad, los errores condicionales tienen distribución normal. Un recordatorio de cuatro supuestos para la inferencia es la sigla **LINI**: linealidad, independencia, normalidad e igualdad de varianzas.

2.9.1. Significado de los coeficientes

El parámetro α es la ordenada al origen de la recta de medias: representa la respuesta promedio cuando $X = 0$. Esta interpretación solo es sustantiva si $X = 0$ tiene sentido en el problema y está dentro de un rango pertinente. El parámetro β es la pendiente: por cada unidad que aumenta X, la media de Y cambia en β unidades. En la muestra, los estimadores a y b dan la recta ajustada $\widehat{y} = a + bx$ y estiman, respectivamente, α y β.

2.10. Representatividad de la recta y variación residual

La recta de mínimos cuadrados resume la tendencia media de los datos, pero ser la mejor recta posible según el criterio de mínimos cuadrados no garantiza que represente bien la nube de puntos. Para describir la distancia de las observaciones a la recta se utilizan los residuos $e_i = y_i - \widehat{y}_i$. Una medida descriptiva de dispersión residual es

$$S_e^2 = \frac{1}{n}\sum_{i=1}^{n} e_i^2 = \frac{SSE}{n}.$$

Valores pequeños indican que, en promedio cuadrático, los datos están cerca de la recta. En inferencia de regresión también es usual estimar la varianza del error mediante $SSE/(n-2)$, pues se estiman dos coeficientes.

2.10.1. Descomposición de la variación

La variación total observada en la respuesta se mide con

$$SST = S_{yy} = \sum_{i=1}^{n} (y_i - \bar{y})^2.$$

En una regresión lineal ajustada por mínimos cuadrados con intercepto, esta variación se descompone en la parte explicada por la recta y la parte residual:

$$\begin{aligned} SST &= SSR + SSE, \\ SSR &= \sum_{i=1}^{n} (\widehat{y}_i - \bar{y})^2, \\ SSE &= \sum_{i=1}^{n} (y_i - \widehat{y}_i)^2 = \sum_{i=1}^{n} e_i^2. \end{aligned}$$

La igualdad expresa que la variación total alrededor de $\bar{y}$ es la suma de la variación de los valores ajustados alrededor de $\bar{y}$ y la variación que queda en los residuos.

Para una observación particular, la desviación total puede separarse en una parte asociada con el ajuste y un residuo:

$$y_i - \bar{y} = (\widehat{y}_i - \bar{y}) + (y_i - \widehat{y}_i).$$

La figura muestra esta relación para el quinto estudiante del ejemplo, para quien $y_i = 92$, $\widehat{y}_i = 84{,}42$ y $\bar{y} = 76$.

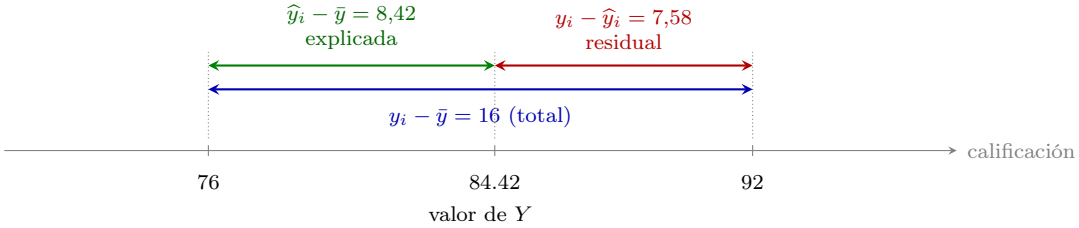


Figura 2.7: Descomposición de la desviación de una observación en una parte explicada por el ajuste y un residuo.

En el ejemplo de las calificaciones, las sumas centradas anteriores son $S_{xx} = C_{XX} = 2474$ y $S_{xy} = C_{XY} = 1894$. Como $b = S_{xy}/S_{xx}$, se obtiene

$$\begin{aligned} SSR &= b^2 S_{xx} = \frac{S_{xy}^2}{S_{xx}} \approx 1449{,}97, \\ SSE &= SST - SSR. \end{aligned}$$

Además, $S_{yy} = \sum y_i^2 - n\bar{y}^2 = 59816 - 10(76)^2 = 2056$, por lo que $SSE \approx 606{,}03$. Se verifica así que $2056 \approx 1449{,}97 + 606{,}03$.

2.11. Coeficiente de determinación

El **coeficiente de determinación**, denotado por R^2, mide la proporción de la variación muestral de Y explicada por la recta de regresión:

$$\begin{aligned} R^2 &= \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \\ &= \frac{S_{xy}^2}{S_{xx} S_{yy}} = r^2, \end{aligned}$$

donde r es el coeficiente de correlación lineal muestral. La igualdad $R^2 = r^2$ se cumple en la regresión lineal simple con intercepto. Aquí $S_{xx} = \sum_i (x_i - \bar{x})^2$, $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$ y $S_{yy} = \sum_i (y_i - \bar{y})^2$.

Con intercepto, $0 \leq R^2 \leq 1$. El porcentaje de variación no explicado por la recta es

$$\frac{SSE}{SST} \cdot 100\,\% = (1 - R^2) \cdot 100\,\%.$$

Para las calificaciones, $R^2 \approx 1449{,}97/2056 \approx 0{,}7052$. Así, la recta explica aproximadamente el 70,52 % de la variación muestral de los puntos de Cálculo; el 29,48 % restante queda en los residuos. Esta proporción describe el ajuste lineal en estos datos y no implica por sí misma una relación causal.

Si $R^2 = 1$, todos los puntos quedan sobre la recta ajustada y existe dependencia lineal funcional en la muestra. Valores cercanos a uno indican que la recta explica una fracción grande de la variación observada. Si $R^2 = 0$, la recta no explica variación lineal respecto de la media de Y; esto no descarta que exista una relación no lineal entre las variables.