Notas de clase

Fundamentos de Estadística I

Semestre 2026-2

Instituto de Matemáticas, Universidad de Antioquia

Autor: Daniel Soto Villada

6 de noviembre de 2026

Índice general

1. Clase 1: Variables bidimensionales y distribuciones de frecuencias **3**
1.1. Variables estadísticas multidimensionales . . . 3
1.1.1. Variable estadística bidimensional . . . 4
1.1.2. Tipos de variables y ejemplos . . . 4
1.2. Distribuciones de frecuencias conjuntas . . . 4
1.2.1. Frecuencia absoluta conjunta . . . 5
1.2.2. Frecuencia relativa conjunta . . . 5
1.3. Ejemplos de distribuciones conjuntas . . . 6
1.3.1. Color de ojos de personas y de sus madres . . . 6
1.3.2. Asistencia mensual al cine y al teatro . . . 6
1.3.3. Ventas y número de trabajadores en empresas . . . 7

2. Clase 2: Distribuciones condicionales y tablas multidimensionales **8**
2.1. Distribuciones condicionales . . . 8
2.1.1. Ejemplo: color de ojos . . . 8
2.1.2. Ejemplo: visitas al cine dado que no se asistió al teatro . . . 9
2.2. Distribuciones conjuntas de tres variables . . . 9
2.3. Pruebas diagnósticas . . . 10

3. Clase 3: Regla de multiplicación y distribuciones condicionales **11**
3.1. Regla de multiplicación de probabilidades . . . 11
3.1.1. Ejemplo: sordera y daltonismo . . . 12
3.2. Distribución conjunta del color de ojos y del cabello . . . 12
3.2.1. Frecuencias absolutas y marginales . . . 12
3.2.2. Frecuencias relativas conjuntas . . . 13
3.3. Perfiles condicionales . . . 13

4. Clase 4: Covarianza y correlación **15**
4.1. Covarianza entre dos variables . . . 15
4.1.1. Definición poblacional . . . 15
4.1.2. Covarianza muestral . . . 15

4.2. El signo de la covarianza en un diagrama de dispersión 15
4.3. Correlación lineal 16

Capítulo 1

Clase 1: Variables bidimensionales y distribuciones de frecuencias

1.1. Variables estadísticas multidimensionales

En un estudio, cada individuo, objeto o unidad observada puede describirse mediante una o varias características. Una **variable estadística k-dimensional** reúne k variables medidas sobre las mismas unidades y se representa por

$$\vec{X} = (X_1, X_2, \ldots, X_k).$$

Para la unidad r, la observación correspondiente es el vector

$$\vec{x}_r = (x_{r1}, x_{r2}, \ldots, x_{rk}), \qquad r = 1, 2, \ldots, n,$$

que contiene los valores registrados de las k variables para esa unidad. El número k indica cuántas características se estudian conjuntamente; n es el número de unidades observadas.

Variable: $\vec{X} = (X_1, X_2, \ldots, X_k)$

Unidad	X_1	X_2	$\cdots$	X_k
1	x_{11}	x_{12}	$\cdots$	x_{1k}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
r	x_{r1}	x_{r2}	$\cdots$	x_{rk}

$\downarrow$

$\vec{x}_r = (x_{r1}, x_{r2}, \ldots, x_{rk})$
valores de las k variables para la unidad r

Figura 1.1: La fila de la unidad r reúne los valores observados de las k variables y forma el vector $\vec{x}_r$.

1.1.1. Variable estadística bidimensional

Cuando se estudian dos características en cada unidad, se tiene una **variable estadística bidimensional**. La representaremos mediante

$$(X, Y).$$

En una muestra de n unidades, los datos son los pares

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n),$$

donde x_r y y_r corresponden siempre a la misma unidad r. En esta clase nos centraremos en describir cómo se distribuyen conjuntamente dos variables, sin perder la correspondencia entre sus observaciones.

1.1.2. Tipos de variables y ejemplos

Cada componente de (X, Y) puede ser cuantitativa o cualitativa. Las variables cuantitativas expresan conteos o mediciones; las cualitativas identifican categorías. La siguiente tabla resume ejemplos:

Tipo de variable	**Ejemplo**	**Valores posibles**
Cuantitativa discreta	Número de visitas al cine en un mes	$0, 1, 2, 3, \ldots$
Cuantitativa continua	Tiempo de traslado al trabajo	Cualquier valor no negativo, por ejemplo 18,5 minutos
Cualitativa nominal	Color de ojos	Café, miel, verde, azul
Cualitativa ordinal	Nivel de satisfacción	Bajo, medio, alto

Cuadro 1.1: Ejemplos de tipos de variables estadísticas.

La clasificación depende de lo que representa cada variable, no de la forma en que se escriben sus valores. Por ejemplo, asignar números a categorías no convierte una variable cualitativa en cuantitativa.

1.2. Distribuciones de frecuencias conjuntas

Una **distribución de frecuencias** organiza y resume los datos indicando cuántas observaciones corresponden a cada valor o categoría. Para dos variables, la **distribución de frecuencias conjunta** presenta las frecuencias de cada combinación de valores de X y de Y.

Sean

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$$

Las observaciones anteriores conforman la muestra. Supongamos que las modalidades o clases de X y de Y son, respectivamente:

$$X: \quad c_1, c_2, \ldots, c_m, \qquad Y: \quad d_1, d_2, \ldots, d_k.$$

La celda (i, j) de la tabla corresponde a la combinación (c_i, d_j).

1.2.1. Frecuencia absoluta conjunta

La **frecuencia absoluta conjunta** n_{ij} cuenta cuántas unidades presentan simultáneamente la modalidad c_i de X y la modalidad d_j de Y:

$$n_{ij} = \#\{r : x_r = c_i \text{ e } y_r = d_j\}.$$

Si los datos están agrupados, $x_r = c_i$ e $y_r = d_j$ se interpreta como que las observaciones pertenecen a las clases indicadas. Las frecuencias absolutas cumplen

$$n_{ij} \geq 0, \qquad \sum_{i=1}^{m} \sum_{j=1}^{k} n_{ij} = n.$$

Las sumas por fila y por columna son las **frecuencias marginales**:

$$n_{i\cdot} = \sum_{j=1}^{k} n_{ij}, \qquad n_{\cdot j} = \sum_{i=1}^{m} n_{ij}.$$

La primera cuenta las unidades con modalidad c_i de X, sin distinguir el valor de Y; la segunda cuenta las unidades con modalidad d_j de Y, sin distinguir el valor de X. Por tanto, ambas sumas marginales dan el total n.

1.2.2. Frecuencia relativa conjunta

La **frecuencia relativa conjunta** f_{ij} es la proporción de observaciones que pertenece a la combinación (c_i, d_j):

$$f_{ij} = \frac{n_{ij}}{n}.$$

Las frecuencias relativas satisfacen

$$0 \leq f_{ij} \leq 1, \qquad \sum_{i=1}^{m} \sum_{j=1}^{k} f_{ij} = 1.$$

Las frecuencias relativas marginales se obtienen sumando por fila o por columna:

$$f_{i\cdot} = \sum_{j=1}^{k} f_{ij} = \frac{n_{i\cdot}}{n}, \qquad f_{\cdot j} = \sum_{i=1}^{m} f_{ij} = \frac{n_{\cdot j}}{n}.$$

La tabla siguiente muestra la estructura general. En cada celda se escribe primero la frecuencia absoluta y, entre paréntesis, la frecuencia relativa correspondiente.

$X \setminus Y$	d_1	$\cdots$	d_j	$\cdots$	d_k	**Total**
c_1	n_{11} (f_{11})	$\cdots$	n_{1j} (f_{1j})	$\cdots$	n_{1k} (f_{1k})	$n_{1\cdot}$ $(f_{1\cdot})$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
c_i	n_{i1} (f_{i1})	$\cdots$	n_{ij} (f_{ij})	$\cdots$	n_{ik} (f_{ik})	$n_{i\cdot}$ $(f_{i\cdot})$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
c_m	n_{m1} (f_{m1})	$\cdots$	n_{mj} (f_{mj})	$\cdots$	n_{mk} (f_{mk})	$n_{m\cdot}$ $(f_{m\cdot})$
Total	$n_{\cdot 1}$ $(f_{\cdot 1})$	$\cdots$	$n_{\cdot j}$ $(f_{\cdot j})$	$\cdots$	$n_{\cdot k}$ $(f_{\cdot k})$	n (1)

Cuadro 1.2: Esquema de una distribución de frecuencias conjunta.

1.3. Ejemplos de distribuciones conjuntas

1.3.1. Color de ojos de personas y de sus madres

La tabla presenta un ejemplo didáctico de frecuencias absolutas para 100 personas. X indica el color de ojos de la persona y Y el color de ojos de su madre. Los valores son conteos ilustrativos y no provienen de una encuesta real.

$X \setminus Y$	**Café**	**Miel**	**Verde**	**Azul**	**Total**
Café	30	5	2	1	38
Miel	6	10	2	1	19
Verde	3	3	8	2	16
Azul	4	2	3	18	27
Total	43	20	15	22	100

Cuadro 1.3: Frecuencias absolutas conjuntas del color de ojos de 100 personas y de sus madres.

Por ejemplo, $n_{12} = 5$ indica que, en este ejemplo, cinco personas tienen ojos café y sus madres tienen ojos color miel. La última fila y la última columna muestran las frecuencias marginales; ambas suman 100.

1.3.2. Asistencia mensual al cine y al teatro

En una muestra de 200 estudiantes universitarios se registró cuántas veces asistieron al cine (X) y al teatro (Y) durante un mes. La tabla muestra las frecuencias relativas conjuntas y marginales; por ello, todas las celdas suman 1.

$X \setminus Y$	**0 veces**	**1 vez**	**2 veces**	**Total**
1 vez	0.200	0.100	0.050	0.350
2 veces	0.125	0.125	0.075	0.325
3 veces	0.050	0.075	0.050	0.175
4 veces	0.040	0.060	0.050	0.150
Total	0.415	0.360	0.225	1.000

Cuadro 1.4: Frecuencias relativas conjuntas de asistencia mensual al cine (X) y al teatro (Y) en una muestra de 200 estudiantes.

La celda correspondiente a $X = 2$ y $Y = 1$ vale $f_{21} = 0{,}125$: el 12.5 % de la muestra asistió dos veces al cine y una vez al teatro. Por ejemplo, ese valor representa 25 estudiantes de los 200 observados.

1.3.3. Ventas y número de trabajadores en empresas

Para 100 pequeñas y medianas empresas se consideran intervalos de volumen de ventas (X) y de número de trabajadores (Y). Esta distribución relativa conserva los conteos del ejemplo: cada valor decimal es la frecuencia absoluta dividida entre 100. Los intervalos de trabajadores no se superponen y cubren de 1 a 99.

$X \setminus Y$	**1–24**	**25–49**	**50–74**	**75–99**	**Total**
1–100	0.28	0.07	0.01	0.00	0.36
101–200	0.10	0.15	0.06	0.02	0.33
201–300	0.04	0.10	0.08	0.09	0.31
Total	0.42	0.32	0.15	0.11	1.00

Cuadro 1.5: Frecuencias relativas conjuntas del volumen de ventas (X) y del número de trabajadores (Y) en 100 empresas.

Así, $f_{23} = 0{,}06$ significa que el 6 % de las empresas (6 de las 100) pertenece al intervalo de ventas 101–200 y tiene entre 50 y 74 trabajadores. La suma de las frecuencias relativas de la tabla es 1.

Capítulo 2

Clase 2: Distribuciones condicionales y tablas multidimensionales

2.1. Distribuciones condicionales

Una distribución condicional describe cómo se distribuye una variable cuando se conoce el valor o la categoría de otra. Sean X y Y dos variables con modalidades $c_1, \ldots, c_m$ y $d_1, \ldots, d_k$, respectivamente. La distribución de X condicionada a $Y = d_j$ considera únicamente las unidades que cumplen esa condición.

La frecuencia absoluta condicional $n_{i|j}$ cuenta las unidades con $X = c_i$ dentro del grupo $Y = d_j$. Por ello, es igual a la frecuencia conjunta n_{ij}. La frecuencia relativa condicional se calcula dividiendo por el total del grupo condicionado:

$$n_{i|j} = n_{ij}, \qquad f_{i|j} = \frac{n_{i|j}}{n_{\cdot j}} = \frac{n_{ij}}{n_{\cdot j}} = \frac{f_{ij}}{f_{\cdot j}}, \quad n_{\cdot j} > 0.$$

Para cada j fijo, $\sum_{i=1}^{m} f_{i|j} = 1$. Análogamente, la distribución de Y condicionada a $X = c_i$ se obtiene con $n_{j|i} = n_{ij}$ y $f_{j|i} = n_{ij}/n_{i\cdot}$, donde $n_{i\cdot} > 0$.

2.1.1. Ejemplo: color de ojos

En la Tabla 1.3 de la Clase 1, X representa el color de ojos de la persona y Y el de su madre. Consideremos claros los colores miel, verde y azul. Al sumar esas columnas, obtenemos la distribución del color de ojos de la persona dado que su madre tiene ojos claros:

Color de ojos (X)	$n_{i\|\textbf{claro}}$	$f_{i\|\textbf{claro}}$	**Porcentaje**
Café	8	8/57	14.04 %
Miel	13	13/57	22.81 %
Verde	13	13/57	22.81 %
Azul	23	23/57	40.35 %
Total	**57**	**1**	**100 %**

Cuadro 2.1: Distribución del color de ojos de la persona dado que el de su madre es claro.

Por ejemplo, para personas con ojos café, la frecuencia condicional es $5 + 2 + 1 = 8$; el total de madres con ojos claros es 57. Así, $f_{\text{café|claro}} = 8/57 \approx 0{,}1404$.

2.1.2. Ejemplo: visitas al cine dado que no se asistió al teatro

En la Tabla 1.4 de la Clase 1, X es el número de visitas al cine y Y el número de visitas al teatro. Para obtener la distribución de X dado $Y = 0$, dividimos las frecuencias de esa columna por su total $f_{\cdot 0} = 0{,}415$. En la muestra de 200 estudiantes, este grupo contiene 83 personas.

Visitas al cine (X)	$n_{i\|0}$	$f_{i\|0}$	**Porcentaje**
1 vez	40	$40/83 \approx 0{,}4819$	48.19 %
2 veces	25	$25/83 \approx 0{,}3012$	30.12 %
3 veces	10	$10/83 \approx 0{,}1205$	12.05 %
4 veces	8	$8/83 \approx 0{,}0964$	9.64 %
Total	**83**	**1**	**100 %**

Cuadro 2.2: Distribución de las visitas al cine entre quienes no asistieron al teatro.

Por ejemplo, entre quienes no fueron al teatro, aproximadamente el 48.19 % fue al cine una vez. Los conteos se obtienen de las frecuencias relativas de la tabla original multiplicadas por 200.

2.2. Distribuciones conjuntas de tres variables

Cuando se observan tres variables simultáneamente, cada unidad se clasifica según una combinación de tres modalidades. Sean i el nivel de estudios, j el medio de comunicación preferido y k el sexo. La frecuencia n_{ijk} cuenta las personas que presentan simultáneamente esas modalidades:

$$n_{ijk} = \#\{r : X_r = c_i,\ Y_r = d_j,\ Z_r = e_k\}, \qquad i = 1, 2; \quad j = 1, 2, 3; \quad k = 1, 2.$$

La siguiente tabla presenta los datos ilustrativos; las filas identifican las combinaciones de nivel de estudios y sexo.

Nivel (i)	**Sexo (k)**	**Prensa ($j=1$)**	**Radio ($j=2$)**	**TV ($j=3$)**	**Total**
Media-básica ($i=1$)	Varón ($k=1$)	30	40	90	160
Media-básica ($i=1$)	Mujer ($k=2$)	25	35	75	135
Superior ($i=2$)	Varón ($k=1$)	80	50	20	150
Superior ($i=2$)	Mujer ($k=2$)	65	55	35	155
Total		**200**	**180**	**220**	**600**

Cuadro 2.3: Frecuencias conjuntas de nivel de estudios, sexo y medio preferido.

Las frecuencias marginales se obtienen sumando sobre los índices que se omiten:

$$n_{i\cdot\cdot} = \sum_{j=1}^{3}\sum_{k=1}^{2} n_{ijk}, \qquad n_{\cdot j\cdot} = \sum_{i=1}^{2}\sum_{k=1}^{2} n_{ijk}, \qquad n_{\cdot\cdot k} = \sum_{i=1}^{2}\sum_{j=1}^{3} n_{ijk},$$
$$n_{ij\cdot} = \sum_{k=1}^{2} n_{ijk}, \qquad n_{i\cdot k} = \sum_{j=1}^{3} n_{ijk}, \qquad n_{\cdot jk} = \sum_{i=1}^{2} n_{ijk}.$$

Por ejemplo, $n_{1\cdot\cdot} = 295$ es el total del nivel media-básica, $n_{\cdot 1\cdot} = 200$ es el total que prefiere la prensa y $n_{\cdot\cdot 1} = 310$ es el total de varones. Además, $n_{1,2,\cdot} = 75$ cuenta a quienes tienen nivel media-básica y prefieren la radio, sin distinguir el sexo.

2.3. Pruebas diagnósticas

Una prueba diagnóstica compara el resultado obtenido con el estado real de las personas. La tabla siguiente resume un ejemplo didáctico de 99 mujeres:

	Prueba positiva	**Prueba negativa**	**Total real**
Embarazada	80	5	85
No embarazada	3	11	14
Total del resultado	**83**	**16**	**99**

Cuadro 2.4: Tabla de contingencia de una prueba diagnóstica.

Un **falso positivo** ocurre cuando la prueba resulta positiva en una persona no embarazada; un **falso negativo**, cuando resulta negativa en una persona embarazada. Los casos restantes son verdaderos positivos y verdaderos negativos. De la tabla se obtienen:

- **Sensibilidad:** proporción de personas embarazadas con resultado positivo, $80/85 \approx 94{,}12\,\%$.
- **Especificidad:** fracción de no embarazadas con prueba negativa: $11/14 \approx 78{,}57\,\%$.
- **Valor predictivo positivo:** proporción de resultados positivos que corresponden a personas embarazadas, $80/83 \approx 96{,}39\,\%$.
- **Valor predictivo negativo:** proporción de resultados negativos que corresponden a personas no embarazadas, $11/16 = 68{,}75\,\%$.

La sensibilidad y la especificidad condicionan por el estado real; los valores predictivos condicionan por el resultado de la prueba. Por ello, responden preguntas distintas.

Capítulo 3

Clase 3: Regla de multiplicación y distribuciones condicionales

3.1. Regla de multiplicación de probabilidades

La regla de multiplicación permite calcular la probabilidad de que dos sucesos ocurran simultáneamente a partir de una probabilidad condicional. Para sucesos A y B, con $P(B) > 0$, la probabilidad de A condicionada a B se define como

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

Despejando $P(A \cap B)$ se obtiene la regla de multiplicación:

$$P(A \cap B) = P(A \mid B)P(B).$$

También puede condicionarse en el otro sentido:

$$P(A \cap B) = P(B \mid A)P(A), \qquad P(A) > 0.$$

En términos intuitivos, la probabilidad de que ocurran ambos sucesos es la probabilidad de que ocurra primero el suceso condicionado multiplicada por la probabilidad de que ocurra el otro dentro de ese grupo. Para tres sucesos, la regla se aplica sucesivamente:

$$P(A \cap B \cap C) = P(A)P(B \mid A)P(C \mid A \cap B),$$

si las probabilidades condicionales están definidas.

3.1.1. Ejemplo: sordera y daltonismo

En una población se estudia la relación entre sordera y daltonismo. Sean S el suceso "la persona es sorda" y D el suceso "la persona es daltónica". La tabla presenta las probabilidades conjuntas y sus probabilidades marginales:

	Sorda (S)	**No sorda (S^c)**	**Total**
Daltónica (D)	0.0004	0.0796	0.0800
No daltónica (D^c)	0.0046	0.9154	0.9200
Total	0.0050	0.9950	1.0000

Cuadro 3.1: Distribución conjunta de sordera y daltonismo.

De la tabla se leen, por ejemplo, $P(S) = 0{,}005$, $P(D) = 0{,}08$ y $P(S \cap D) = 0{,}0004$. La probabilidad de que una persona sea sorda o daltónica es

$$P(S \cup D) = P(S) + P(D) - P(S \cap D) = 0{,}005 + 0{,}08 - 0{,}0004 = 0{,}0846.$$

Además,

$$P(S \mid D) = \frac{P(S \cap D)}{P(D)} = \frac{0{,}0004}{0{,}08} = 0{,}005, \qquad P(D \mid S) = \frac{P(S \cap D)}{P(S)} = \frac{0{,}0004}{0{,}005} = 0{,}08.$$

En este ejemplo, $P(S \cap D) = P(S)P(D) = 0{,}005 \cdot 0{,}08 = 0{,}0004$. Por tanto, S y D son independientes: conocer si la persona es daltónica no cambia la probabilidad de sordera, y viceversa. En general, dos sucesos son independientes si $P(A \cap B) = P(A)P(B)$ (equivalentemente, cuando las probabilidades condicionales están definidas, $P(A \mid B) = P(A)$).

3.2. Distribución conjunta del color de ojos y del cabello

Se consideran 5387 personas, clasificadas por color de ojos (X) y color de cabello (Y). Sean $c_1, \ldots, c_4$ las categorías de ojos (claros, azules, medio y oscuros) y $d_1, \ldots, d_5$ las categorías de cabello (rubio, rojo, medio, oscuro y negro). La frecuencia absoluta conjunta n_{ij} cuenta las personas que pertenecen simultáneamente a la categoría de ojos c_i y a la de cabello d_j.

3.2.1. Frecuencias absolutas y marginales

Color de ojos (X)	**Rubio**	**Rojo**	**Medio**	**Oscuro**	**Negro**	**Total**
Claros (c_1)	688	116	584	188	4	1580
Azules (c_2)	326	38	241	110	3	718
Medio (c_3)	343	84	909	412	26	1774
Oscuros (c_4)	98	48	403	681	85	1315
Total	**1455**	**286**	**2137**	**1391**	**118**	**5387**

Cuadro 3.2: Frecuencias absolutas conjuntas n_{ij} del color de ojos y del cabello.

Las sumas por fila y columna son las frecuencias marginales: $n_{i\cdot} = \sum_j n_{ij}$ y $n_{\cdot j} = \sum_i n_{ij}$. La suma de todas las frecuencias es $n = 5387$.

3.2.2. Frecuencias relativas conjuntas

La frecuencia relativa conjunta es $f_{ij} = n_{ij}/n$. La siguiente tabla expresa estas proporciones como porcentajes del total; por redondeo a dos decimales, algunas sumas visuales pueden diferir levemente de 100,00.

Frecuencias relativas conjuntas (%)						
Color de ojos (X)	**Rubio**	**Rojo**	**Medio**	**Oscuro**	**Negro**	**Total**
Claros (c_1)	12.77	2.15	10.84	3.49	0.07	29.33
Azules (c_2)	6.05	0.71	4.47	2.04	0.06	13.33
Medio (c_3)	6.37	1.56	16.87	7.65	0.48	32.93
Oscuros (c_4)	1.82	0.89	7.48	12.64	1.58	24.41
Total	**27.01**	**5.31**	**39.67**	**25.82**	**2.19**	**100.00**

Cuadro 3.3: Frecuencias relativas conjuntas f_{ij}, expresadas como porcentaje del total.

3.3. Perfiles condicionales

Los perfiles muestran distribuciones condicionales a partir de la tabla conjunta. El perfil fila divide cada celda por el total de su fila, por lo que describe el color de cabello dado el color de ojos:

$$f_{j|i} = \frac{n_{ij}}{n_{i\cdot}}, \qquad \sum_{j=1}^{5} f_{j|i} = 1.$$

Color de ojos (X)	**Rubio**	**Rojo**	**Medio**	**Oscuro**	**Negro**	**Total**
Claros (c_1)	0.4354	0.0734	0.3696	0.1190	0.0025	1.0000
Azules (c_2)	0.4540	0.0529	0.3357	0.1532	0.0042	1.0000
Medio (c_3)	0.1933	0.0474	0.5124	0.2322	0.0147	1.0000
Oscuros (c_4)	0.0745	0.0365	0.3065	0.5179	0.0646	1.0000
Perfil marginal del cabello	**0.2701**	**0.0531**	**0.3967**	**0.2582**	**0.0219**	**1.0000**

Cuadro 3.4: Perfiles fila: distribución del color de cabello condicionada al color de ojos.

El perfil marginal del cabello se obtiene de las frecuencias marginales $n_{\cdot j}/n$ y es el centroide de los perfiles fila ponderados por las proporciones de cada categoría de ojos.

El perfil columna divide cada celda por el total de su columna. Describe el color de ojos dado el color de cabello:

$$f_{i|j} = \frac{n_{ij}}{n_{\cdot j}}, \qquad \sum_{i=1}^{4} f_{i|j} = 1.$$

Color de ojos (X)	**Rubio**	**Rojo**	**Medio**	**Oscuro**	**Negro**	**Marginal de X**
Claros (c_1)	0.4729	0.4056	0.2733	0.1352	0.0339	0.2933
Azules (c_2)	0.2241	0.1329	0.1128	0.0791	0.0254	0.1333
Medio (c_3)	0.2357	0.2937	0.4254	0.2962	0.2203	0.3293
Oscuros (c_4)	0.0674	0.1678	0.1886	0.4896	0.7203	0.2441
Total	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**

Cuadro 3.5: Perfiles columna: distribución del color de ojos condicionada al color de cabello.

El perfil marginal de ojos está formado por las proporciones $n_{i\cdot}/n$ y corresponde al centroide de los perfiles columna ponderados por las proporciones de cada categoría de cabello. Los perfiles fila y columna permiten comparar distribuciones condicionales; sus valores no deben confundirse con las frecuencias relativas conjuntas.

Capítulo 4

Clase 4: Covarianza y correlación

4.1. Covarianza entre dos variables

Consideremos dos variables cuantitativas X y Y, observadas conjuntamente en n unidades. Para cada observación i, el par (x_i, y_i) indica los valores de ambas variables en la misma unidad. La covarianza describe si, en promedio, las desviaciones de X y de Y respecto de sus medias tienden a tener el mismo signo o signos opuestos.

4.1.1. Definición poblacional

Si la población contiene N pares (x_i, y_i), su covarianza se define como

$$\mathrm{Cov}(X, Y) = \sigma_{XY} = \frac{1}{N} \sum_{i=1}^{N} (x_i - \mu_X)(y_i - \mu_Y),$$

donde μ_X y μ_Y son las medias poblacionales de X y Y. La sumatoria agrega, para cada individuo, el producto de las dos desviaciones con respecto a sus medias.

4.1.2. Covarianza muestral

Cuando se dispone de una muestra de n pares, se utiliza la covarianza muestral

$$s_{XY} = \mathrm{cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}),$$

donde $\bar{x}$ y $\bar{y}$ son las medias muestrales. El divisor $n - 1$ es el habitual para estimar la covarianza poblacional a partir de una muestra.

4.2. El signo de la covarianza en un diagrama de dispersión

En un diagrama de dispersión, las líneas $x = \bar{x}$ y $y = \bar{y}$ separan el plano en cuatro regiones. El signo de la contribución de cada observación a la suma de covarianza depende del producto

$(x_i - \bar{x})(y_i - \bar{y})$:

- Si $x_i > \bar{x}$ y $y_i > \bar{y}$, ambas desviaciones son positivas y su producto es positivo.
- Si $x_i < \bar{x}$ y $y_i < \bar{y}$, ambas desviaciones son negativas y su producto también es positivo.
- Si una observación queda por encima de una media y por debajo de la otra, las desviaciones tienen signos opuestos y su producto es negativo.

La figura ilustra cómo se suman estas contribuciones. Una covarianza positiva aparece cuando predominan los productos positivos; una negativa, cuando predominan los productos negativos. Los puntos exactamente sobre una de las medias aportan cero.

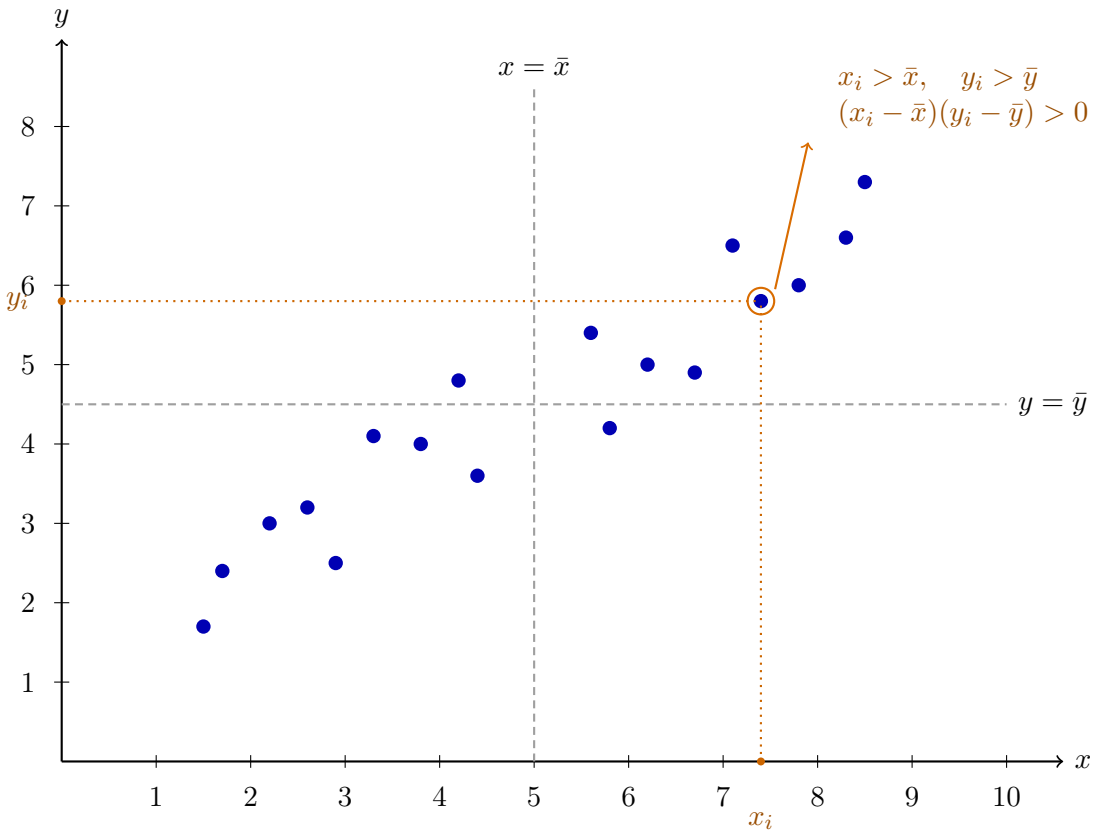


Figura 4.1: Las desviaciones respecto de las medias tienen productos positivos en los cuadrantes superior derecho e inferior izquierdo, y negativos en los otros dos.

La covarianza informa la dirección de la variación conjunta, pero su magnitud depende de las unidades de medición. Por ello, no existe un límite fijo común para sus valores y no debe compararse directamente entre pares de variables medidos en escalas distintas.

4.3. Correlación lineal

La correlación estandariza la covarianza dividiéndola por el producto de las desviaciones estándar. Para una población, el coeficiente de correlación lineal es

$$\rho_{XY} = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

Para una muestra, se calcula mediante

$$r_{XY} = \frac{s_{XY}}{s_X s_Y},$$

donde s_X y s_Y son las desviaciones estándar muestrales. Siempre que ambas variables tengan variabilidad, el coeficiente cumple $-1 \leq r_{XY} \leq 1$:

- $r_{XY} > 0$ indica asociación lineal positiva: los valores mayores de una variable tienden a acompañarse de valores mayores de la otra.
- $r_{XY} < 0$ indica asociación lineal negativa: los valores mayores de una variable tienden a acompañarse de valores menores de la otra.
- Un valor cercano a cero indica poca asociación lineal; no descarta una relación no lineal.
- $r_{XY} = 1$ o $r_{XY} = -1$ corresponde a una relación lineal positiva o negativa perfecta en los datos.

La correlación no depende de las unidades de medida, a diferencia de la covarianza, pero describe únicamente la intensidad y dirección de la asociación lineal. Por sí sola no demuestra una relación de causa y efecto.