Exploración descriptiva del conjunto de datos `survey`

Nicol Dayana Vasquez Zapata[a], Daniel Soto Villada[b]

[a] *Pregrado en Estadística, Universidad de Antioquia, Colombia*
[b] *Pregrado en Astronomía, Universidad de Antioquia, Colombia*

14 de octubre de 2026

Resumen

En este informe se resume una exploración descriptiva del conjunto `survey` del paquete `MASS` en R. Se trabajó con seis variables: sexo, mano dominante, amplitud de la mano dominante y no dominante, pulso y estatura. Se revisaron valores faltantes, se construyeron tablas de frecuencia y se calcularon medidas descriptivas básicas para entender el perfil general de los estudiantes.

1. Introducción

Este trabajo busca describir, de forma clara y breve, cómo son los datos de una encuesta aplicada a estudiantes. El enfoque es descriptivo: primero se revisa la calidad de la base y luego se presentan tablas y resúmenes numéricos.

Aquí falta agregar una motivación personal del grupo sobre por qué este conjunto de datos es útil para el curso.

2. Materiales y métodos

2.1. Base de datos y variables

Se utilizó el conjunto `survey` del paquete `MASS`. En total hay 237 registros. Para este informe se seleccionaron las variables `Sex`, `W.Hnd`, `Wr.Hnd`, `NW.Hnd`, `Pulse` y `Height`.

Variable	Descripción	Tipo
`Sex`	Sexo reportado (Female/Male).	Cualitativa nominal
`W.Hnd`	Mano dominante para escribir (Left/Right).	Cualitativa nominal
`Wr.Hnd`	Amplitud de la mano con la que escribe (cm).	Cuantitativa continua
`NW.Hnd`	Amplitud de la mano no dominante (cm).	Cuantitativa continua
`Pulse`	Pulso en reposo (latidos por minuto).	Cuantitativa (discreta)
`Height`	Estatura (cm).	Cuantitativa continua

2.2. Tratamiento de valores faltantes

Se identificaron valores faltantes en todas las variables seleccionadas. Los faltantes fueron: 1 en `Sex`, 1 en `W.Hnd`, 1 en `Wr.Hnd`, 1 en `NW.Hnd`, 45 en `Pulse` y 28 en `Height`. Para algunos análisis se trabajó con casos completos, quedando 168 observaciones sin NA.

Aquí falta decidir y justificar si el análisis final se reportará siempre con casos completos o variable por variable.

2.3. Procedimiento en R

Se usaron tablas de frecuencia para variables cualitativas y medidas de resumen para variables cuantitativas (media, mediana, cuartiles, desviación estándar y rango intercuartílico).

Código clave usado en la preparación:

```
library(MASS)
data(survey)
survey_filtrado <- survey[, c("Sex", "Wr.Hnd", "NW.Hnd", "W.Hnd", "Pulse", "Height")]
colSums(is.na(survey_filtrado))
```

3. Resultados y análisis

3.1. Variables cualitativas

En `Sex` hubo 236 casos válidos: 118 mujeres (50 %) y 118 hombres (50 %). En `W.Hnd` hubo 236 casos válidos: 218 diestros (92.37 %) y 18 zurdos (7.63 %).

Estos resultados muestran una distribución equilibrada por sexo y una mayoría amplia de estudiantes diestros.

3.2. Variables cuantitativas

Resumen principal (sobre casos válidos por variable):

- `Wr.Hnd`: media 18.67, mediana 18.5, Q1=17.5, Q3=19.8.
- `NW.Hnd`: media 18.58, mediana 18.5, Q1=17.5, Q3=19.72.
- `Pulse`: media 74.15, mediana 72.5, Q1=66, Q3=80.
- `Height`: media 172.38, mediana 171, Q1=165, Q3=180.

Los valores centrales de `Wr.Hnd` y `NW.Hnd` son muy parecidos. En `Height`, la mitad central de los datos está entre 165 y 180 cm. En `Pulse`, la mayor concentración aparece alrededor de 68 a 80 latidos por minuto.

Código clave para resúmenes:

```
summary(survey_filtrado[, c("Wr.Hnd", "NW.Hnd", "Pulse", "Height")])
quantile(survey_filtrado$Height, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

3.3. Atípicos y distribución

Con la regla $1{,}5 \times RIC$ se observaron atípicos en `Wr.Hnd`, `NW.Hnd` y `Pulse`; por ejemplo, un pulso de 35 y registros de 104 latidos por minuto.

Aquí falta incluir una figura final (boxplot o histograma) y comentar brevemente qué cambia con y sin atípicos.

4. Conclusiones

La exploración descriptiva permitió identificar el perfil básico de la muestra y la calidad de los datos. En términos generales, las amplitudes de mano están concentradas cerca de 18.5 cm, la estatura alrededor de 171–172 cm y el pulso en torno a 72–74 latidos por minuto.

Aquí falta redactar una conclusión final conectada con los objetivos del curso y proponer una pregunta para análisis inferencial.